

MINISTERUL EDUCAȚIEI ȘI CERCETĂRII ȘTIINȚIFICE



UNIVERSITATEA TEHNICĂ

DIN CLUJ-NAPOCA

FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL AUTOMATICĂ

**LINIARIZARE ROBUSTĂ PRIN REACȚIE DE LA STARE - O ABORDARE
DATA-DRIVEN**

LUCRARE DE DIPLOMĂ

Absolvent: **Andreea-Adelina PENCIUC**
Conducător științific: **ȘL. dr. ing. Vlad Mihai MIHALY**

2026

Cuprins

Capitolul 1	Introducere	11
1.1	Context general	11
1.2	Obiective	13
1.3	Specificații	14
Capitolul 2	Studiu Bibliografic	16
2.1	Fundamente ale liniarizării prin reacție de la stare	16
2.2	De la model cunoscut la abordarea bazată pe date	18
2.3	Rolul dicționarelor de funcții în metodele data-driven	19
2.4	Liniarizarea prin reacție de la stare din perspectiva datelor	19
2.5	Influența datelor zgomotoase în controlul bazat pe date	21
2.6	Metode numerice de reducere a efectului zgomotului	22
Capitolul 3	Analiză, Proiectare și Implementare	24
3.1	Analiză și Fundamentare Teoretică	24
3.1.1	Formularea problemei și liniarizarea clasică prin reacție de la stare .	24
3.1.2	Reformularea problemei din perspectiva data-driven	29
3.1.3	Parametrizarea funcțiilor și ecuația de identificare	32
3.1.4	Extinderea problemei pentru cazul cu date zgomotoase	37
3.1.5	Normalizarea și regularizarea problemei de identificare	41
3.2	Proiectare și Implementare	45
3.2.1	Prezentarea generală a implementării MATLAB	45
3.2.2	Structura funcțională a codului	47
3.2.3	Sisteme utilizate în implementare	50
3.2.4	Definirea dicționarelor și pregătirea datelor	51
3.2.5	Construirea relațiilor de identificare și calculul coeficienților	52
3.2.6	Verificarea soluțiilor obținute și criterii de admisibilitate	54
3.2.7	Organizarea rezultatelor în interfața aplicației	56
3.3	Testare și Validare	57
3.3.1	Metodologia de testare	57
3.3.2	Generarea datelor în simulare și influența zgomotului	58
3.3.3	Validarea metodei în cazul fără zgomot	61

3.3.4	Validarea metodei în cazul cu date zgomotoase	61
3.3.5	Compararea metodelor de identificare	63
3.3.6	Validare în buclă închisă	64
3.3.7	Sinteza rezultatelor obținute	67
Capitolul 4	Concluzii	68
4.1	Sinteza lucrării	68
4.2	Rezultate obținute și contribuții	69
4.3	Direcții de dezvoltare	71
Bibliografie		73

Capitolul 1

Introducere

1.1 Context general

Controlul automat reprezintă o componentă esențială în ingineria modernă, deoarece permite conducerea sistemelor tehnice astfel încât acestea să respecte un comportament impus. În practică, un sistem de control poate fi proiectat pentru a îndeplini mai multe cerințe, cum ar fi menținerea stabilității, urmărirea unei valori de referință, atenuarea perturbațiilor sau îmbunătățirea caracteristicilor de răspuns. Astfel de cerințe apar într-o gamă largă de aplicații reale, de la sisteme mecanice și acționări electrice până la robotică, procese industriale sau sisteme autonome, motiv pentru care controlul automat rămâne un domeniu important atât din punct de vedere teoretic, cât și practic.

În multe situații, analiza și proiectarea unui sistem de control pornesc de la un model matematic al procesului. Acest model poate fi liniar sau neliniar, în funcție de complexitatea fenomenelor descrise și de domeniul de funcționare luat în considerare. Modelele liniare sunt utilizate frecvent datorită simplității lor analitice și compatibilității cu metodele clasice de proiectare, însă majoritatea sistemelor reale prezintă, într-o anumită măsură, un comportament neliniar. Un model liniar poate aproxima satisfăcător dinamica sistemului în vecinătatea unui punct de funcționare, dar atunci când domeniul de operare se extinde, neliniaritățile devin semnificative și nu mai pot fi neglijate fără a afecta calitatea analizei sau a controlului. Neliniaritățile apar în mod natural în sistemele reale, fiind produse de fenomene precum saturații, frecări, cuplaje între variabile sau relații complexe care nu pot fi descrise suficient de bine printr-o relație liniară simplă. Din acest motiv, controlul sistemelor neliniare reprezintă o direcție importantă în automatică, deoarece permite tratarea unor situații în care modelele liniare nu mai sunt suficiente. Metodele neliniare țin cont de structura reală a sistemului și pot conduce la performanțe mai bune, mai ales atunci când neliniaritățile au un rol important în dinamica procesului.

Una dintre tehnicile reprezentative pentru controlul sistemelor neliniare este liniarizarea prin reacție de la stare [1, 2]. Spre deosebire de liniarizarea clasică în jurul unui punct de funcționare, care produce un model liniar valabil doar local, liniarizarea prin feedback urmărește transformarea sistemului neliniar într-un sistem liniar echivalent, printr-o

schimbare de coordonate și printr-o lege de comandă adecvată [3]. După realizarea acestei transformări, proiectarea regulatorului se reduce la o problemă de control liniar, ceea ce permite utilizarea unor metode consacrate pentru analiza stabilității și alegerea comportamentului în buclă închisă.

Principiul metodei se bazează pe noțiuni precum derivata Lie, gradul relativ, transformarea de coordonate și termenul de decuplare, concepte prin intermediul cărora se poate stabili dacă un sistem neliniar poate fi adus într-o formă liniară echivalentă și care este legea de comandă necesară pentru realizarea acestei transformări. Această abordare este importantă deoarece oferă o legătură directă între teoria controlului neliniar și metodele de control liniar, permițând controlul unor sisteme neliniare printr-o structură mai ușor de analizat și proiectat.

Metoda are însă și limitări importante. În forma sa clasică, liniarizarea prin reacție de la stare presupune cunoașterea completă a modelului matematic al sistemului. Într-un context teoretic sau în simulări, unde ecuațiile sistemului sunt disponibile explicit, această ipoteză este rezonabilă. În aplicații reale, însă, modelul poate fi incomplet sau afectat de incertitudini, iar parametrii pot fi necunoscuți, aproximați sau variabili în timp. Dacă modelul utilizat nu descrie suficient de bine procesul real, compensarea neliniarităților poate deveni imprecisă, iar performanțele în buclă închisă se pot degrada.

Această dificultate motivează utilizarea metodelor bazate pe date. În controlul data-driven, accentul nu mai cade exclusiv pe identificarea completă a modelului matematic, ci pe extragerea informației utile direct din datele măsurate sau generate prin simulare. În multe situații, colectarea datelor este mai accesibilă decât obținerea unui model analitic complet, mai ales atunci când sistemul este complex, are parametri greu de determinat sau include fenomene dificil de modelat. În contextul liniarizării prin reacție de la stare, abordarea data-driven urmărește determinarea funcțiilor necesare liniarizării pornind de la date, păstrând ideea metodei clasice, dar reducând dependența de modelul cunoscut.

O astfel de abordare este prezentată în lucrări recente, în care liniarizarea prin feedback este reformulată din perspectiva datelor disponibile, fără a porni de la cunoașterea explicită a modelului [4]. În această lucrare, direcția respectivă este folosită ca punct de plecare pentru implementarea și testarea unei metode de liniarizare prin reacție de la stare bazată pe date. Modelele sistemelor sunt utilizate pentru generarea datelor și pentru verificarea rezultatelor, însă etapa de identificare urmărește obținerea elementelor necesare liniarizării direct din datele disponibile.

Pe lângă avantajele pe care le introduce, abordarea data-driven aduce și dificultăți suplimentare. Calitatea rezultatelor depinde de datele utilizate, de modul în care acestea acoperă dinamica relevantă a sistemului și de nivelul zgomotului prezent în măsurători. În aplicațiile reale, stările măsurate pot fi afectate de erori ale senzorilor, perturbații nemăsurabile sau cuantizare, iar aceste efecte pot influența puternic procesul de identificare. În plus, estimarea derivatelor din date zgomotoase poate amplifica erorile, ceea ce face ca analiza cazului cu date perturbate să fie o etapă importantă în evaluarea metodei.

Această lucrare se încadrează la intersecția dintre controlul neliniar și metodele moderne bazate pe date. Liniarizarea prin reacție de la stare reprezintă un punct de plecare

potrivit pentru această analiză, deoarece oferă o structură clară: transformare de coordonate, termen de compensare, termen de decuplare și lege de comandă. Comparativ cu alte tehnici neliniare, această metodă permite o reformulare data-driven mai directă, deoarece elementele necesare liniarizării pot fi approximate prin dicționare de funcții candidate și determinate din datele disponibile.

Lucrarea este organizată astfel încât să urmărească treptat trecerea de la teoria clasică la implementarea și validarea unei metode data-driven. Capitolul 1 prezintă contextul general, obiectivele și specificațiile lucrării. Capitolul 2 conține studiul bibliografic, în care sunt prezentate noțiuni legate de liniarizarea prin reacție de la stare, metode data-driven, dicționare de funcții și metode de reducere a efectului zgomotului. Capitolul 3 reprezintă partea principală a lucrării și include analiza teoretică, implementarea în MATLAB, construcția relațiilor de identificare, testarea metodelor și validarea în buclă închisă. Capitolul 4 sintetizează rezultatele obținute, contribuțiile personale, limitele abordării și direcțiile posibile de dezvoltare.

1.2 Obiective

Obiectivul general al acestei lucrări este implementarea și analiza unei metode de liniarizare prin reacție de la stare bazată pe date pentru sisteme neliniare cu grad relativ complet. Lucrarea urmărește trecerea graduală de la cazul clasic, în care modelul matematic al sistemului este cunoscut, la cazul în care elementele necesare liniarizării sunt identificate folosind date generate de sistem.

Pentru atingerea obiectivului general, s-au stabilit următoarele **obiective specifice**:

- Prezentarea cadrului teoretic al liniarizării prin reacție de la stare pentru sisteme neliniare afine în intrare, prin introducerea noțiunilor de grad relativ, transformare de coordonate, termen de decuplare, lege de control și formă liniarizată utilizată pentru proiectarea regulatorului;
- Analizarea trecerii de la cazul clasic, bazat pe model matematic cunoscut, la formularea data-driven a problemei, în care funcțiile necesare liniarizării sunt reconstruite pe baza datelor disponibile și a unor dicționare de funcții candidate alese în funcție de dinamica sistemului;
- Construirea relațiilor de identificare pentru determinarea coeficienților necunoscuți ai funcțiilor necesare liniarizării, cu includerea condițiilor de normalizare, a criteriilor de admisibilitate și a verificărilor necesare utilizării soluțiilor în legea de control;
- Evaluarea influenței zgomotului asupra datelor de stare și asupra estimării derivatelor, prin compararea cazului ideal, fără zgomot, cu situația în care stările măsurate sunt perturbate, iar intrarea aplicată este considerată cunoscută, neperturbată și salvată în timpul simulării;

- Compararea variantelor de identificare pentru date perturbate, respectiv aplicarea directă pe date zgomotoase, forma derivativă cu filtrare și regularizare Tikhonov și forma integrală regularizată, în vederea selectării metodei care oferă soluții admisibile și stabile numeric;
- Validarea soluțiilor obținute prin simulări numerice în MATLAB, pe sisteme neliniare cu o singură intrare și o singură ieșire, precum și pe sisteme cu mai multe intrări și mai multe ieșiri, urmărind comportarea în buclă închisă, convergența stărilor și nivelul semnalului de comandă.

Prin aceste obiective, lucrarea urmărește un parcurs complet, de la familiarizarea cu metoda clasică de liniarizare prin reacție de la stare până la implementarea și validarea unei variante data-driven, accentul fiind pus pe cazul datelor afectate de zgomot, deoarece acesta este mai apropiat de condițiile practice în care măsurătorile nu sunt ideale.

1.3 Specificații

Tema lucrării constă în studiul, implementarea și validarea unei metode de liniarizare prin reacție de la stare din perspectivă data-driven. Lucrarea pornește de la cazul clasic, caracterizat prin cunoașterea modelului matematic al sistemului, și urmărește apoi determinarea din date a elementelor necesare liniarizării. Accentul principal este pus pe cazul în care datele de stare sunt afectate de zgomot, iar intrarea de comandă este considerată cunoscută și neperturbată.

Lucrarea se concentrează pe sisteme neliniare afine în intrare, descrise prin forma:

$$\begin{cases} \dot{x} = f(x) + g(x)u \\ y = h(x) \end{cases} \quad (1.1)$$

unde x reprezintă vectorul de stare, u reprezintă intrarea de comandă, iar y reprezintă ieșirea sistemului. Funcțiile $f(x)$ și $g(x)$ descriu dinamica sistemului și modul în care comanda influențează starea, iar $h(x)$ definește mărimea de ieșire în raport cu care se analizează gradul relativ. Această formă este frecvent întâlnită în teoria controlului neliniar și permite aplicarea liniarizării prin reacție de la stare în condiții specifice. În lucrare sunt analizate atât sisteme SISO, cu o singură intrare și o singură ieșire, cât și sisteme MIMO, cu mai multe intrări și mai multe ieșiri, cu grad relativ complet.

Punctul de plecare este reprezentat de cazul clasic de liniarizare prin reacție de la stare, în care modelul matematic al sistemului este cunoscut. Această etapă are rolul de a prezenta principiul metodei și modul în care un sistem neliniar poate fi transformat într-o formă liniară, mai ușor de controlat, prin calculul unei legi de control care compensează neliniaritățile sistemului.

Etapa principală a lucrării urmărește abordarea bazată pe date. În această etapă, accentul se mută de la folosirea directă a expresiilor analitice la obținerea informațiilor nece-

sare liniarizării din date generate prin simulare. Modelele sistemelor sunt folosite pentru generarea datelor și pentru verificarea rezultatelor, însă etapa de identificare evidențiază perspectiva data-driven, deoarece datele disponibile sunt folosite pentru a obține elementele necesare liniarizării.

Din punct de vedere al datelor, lucrarea analizează atât cazul ideal, fără zgomot, cât și cazul în care stările măsurate sunt afectate de zgomot. În cazul datelor curate, metoda de bază folosește spațiul nul al matricei de identificare, calculat prin descompunerea în valori singulare (SVD), pentru determinarea coeficienților necunoscuți. În cazul datelor zgomotoase, sunt comparate mai multe variante de identificare: aplicarea directă pe date perturbate, metoda bazată pe derivate filtrate cu regularizare Tikhonov și forma integrală regularizată. Scopul acestei comparații este de a evidenția sensibilitatea metodei la zgomot și de a selecta varianta care conduce la soluții admisibile, stabile numeric și utilizabile în buclă închisă.

Pentru acceptarea unei soluții nu este suficientă obținerea unui reziduu mic al relației de identificare. Soluțiile trebuie verificate și din punctul de vedere al admisibilității, deoarece o soluție numerică bună nu garantează automat o transformare de coordonate validă sau un termen de decuplare utilizabil. Astfel, sunt analizate condițiile asupra transformării de coordonate și asupra termenului de decuplare. În cazul sistemelor SISO se urmărește ca termenul de decuplare să nu se apropie de zero, iar în cazul sistemelor MIMO se urmărește ca matricea de decuplare să rămână inversabilă pe regiunea de validare.

Implementarea este realizată în mediul MATLAB și permite simularea sistemelor, generarea datelor, introducerea zgomotului, prelucrarea semnalelor, construirea matricelor de identificare, aplicarea metodelor numerice, calculul coeficienților și validarea soluțiilor obținute. Aceasta este gândită pentru mai multe sisteme neliniare, astfel încât să se poată observa comportarea metodei atât în cazuri simple, cât și în cazuri mai complexe. În cadrul lucrării este realizată și o interfață MATLAB, cu rolul de a organiza rezultatele, de a afișa indicatorii numerici și de a facilita analiza graficelor obținute.

Validarea finală se realizează în buclă închisă. Pentru fiecare soluție acceptată se construiește legea de control și se simulează evoluția sistemului neliniar controlat, fiind urmărite evoluția stărilor, stabilizarea către punctul de echilibru, eroarea finală, valoarea maximă a comenzii și valoarea medie pătratică (RMS) a comenzii. Regulatorul este proiectat pe forma liniarizată a sistemului, iar matricea de reacție este aleasă astfel încât dinamica în buclă închisă să fie stabilă.

Prin aceste elemente, lucrarea urmărește nu doar identificarea unor coeficienți, ci și verificarea comportamentului sistemului controlat, deoarece o soluție este utilă doar dacă poate fi folosită efectiv în simularea sistemului în buclă închisă.

Capitolul 2

Studiu Bibliografic

2.1 Fundamente ale liniarizării prin reacție de la stare

Sistemele neliniare apar tot mai des în aplicațiile de automatică, deoarece majoritatea proceselor reale nu pot fi descrise suficient de bine prin modele liniare pe întregul domeniu de funcționare. În cazul sistemelor liniare, legăturile dintre stări, intrări și ieșiri sunt mult mai ușor de analizat, fiind disponibile metode bine stabilite pentru proiectarea regulatorului, în timp ce în cazul sistemelor neliniare, comportamentul depinde mult mai puternic de forma ecuațiilor, de punctul de funcționare și de tipul neliniarităților prezente. În lucrarea [5], Byrnes și Isidori subliniază cât de importantă este existența unor metode sistematice de proiectare a legilor de comandă în buclă închisă pentru astfel de sisteme, mai ales când apar obiective precum stabilizare, urmărirea unei referințe sau robustețe față de anumite perturbații.

O astfel de metodă este liniarizarea prin reacție de la stare. Boufadene, în lucrarea [3], prezintă această tehnică ca fiind o abordare consacrată în controlul neliniar, tehnica prin care are loc transformarea dinamicii neliniare într-o formă mai simplă, liniară, comandată printr-o nouă intrare virtuală, care să permită folosirea unor metode generale și bine cunoscute de analiză și proiectare. Din punct de vedere teoretic, liniarizarea prin reacție își are rădăcinile în controlul geometric. În lucrarea [6], Brockett studiază invarianții sistemelor neliniare sub transformări de feedback și evidențiază un aspect important: nu orice proprietate a unui sistem poate fi eliminată printr-o alegere corectă a comenzii, ci anumite caracteristici sunt specifice structurii interne a sistemului, concluzie din care rezultă că posibilitatea liniarizării unui sistem neliniar nu depinde doar de legea de comandă aleasă, ci și de proprietățile geometrice ale sistemului.

Pentru fundamentele teoretice ale controlului neliniar și ale liniarizării prin reacție de la stare, lucrările lui Isidori și Nijmeijer-van der Schaft reprezintă referințe importante. Acestea prezintă cadrul geometric al metodei și explică noțiuni precum câmpurile vectoriale, derivatele Lie, gradul relativ, transformarea de coordonate și condițiile în care un sistem neliniar poate fi transformat într-o formă liniară echivalentă [1, 2]. Din această perspectivă, liniarizarea prin feedback nu este doar o metodă de compensare a neliniarităților,

ci o procedură care depinde de structura internă a sistemului și de posibilitatea construirii unei schimbări de coordonate valide. Această interpretare este importantă pentru lucrarea de față, deoarece metodele data-driven utilizate ulterior încearcă să obțină din date tocmai aceste elemente care, în abordarea clasică, sunt calculate pornind de la modelul matematic cunoscut.

Direcția aceasta este dezbătută de *Jakubczyk* și *Respondek* în lucrarea [7], considerată în literatura de specialitate una dintre referințele de bază privind condițiile de liniarizare a sistemelor. În studiul bibliografic este o referință importantă deoarece arată că liniarizarea prin reacție nu este doar o procedură de calcul, ci implică și condiții structurale precise. În cadrul lucrării de față, această perspectivă motivează urmărirea unor proprietăți precum gradul relativ al sistemului, existența unei transformări de coordonate adecvate și inversabilitatea matricei de decuplare în cazul sistemelor MIMO.

O categorie relevantă de sisteme neliniare o constituie cea a sistemelor afine în intrare, sisteme în care dinamica poate fi neliniară în raport cu stările, însă semnalul de intrare intervine liniar în ecuațiile de stare. În mod general, un astfel de sistem poate fi descris prin relația:

$$\dot{x} = f(x) + g(x)u, \quad (2.1)$$

unde x este vectorul de stare, u este intrarea de control, iar funcțiile $f(x)$ și $g(x)$ descriu dinamica sistemului și modul în care comanda influențează starea.

În cazul liniarizării prin reacție de la stare, sistemului i se atașează o mărime de ieșire, definită prin:

$$y = h(x), \quad (2.2)$$

unde y este ieșirea sistemului, iar $h(x)$ este funcția de ieșire. În lucrarea [3], Boufadene abordează tehnica liniarizării prin reacție de la stare pornind de la această reprezentare, având ca scop obținerea unei legături liniare intrare-ieșire între noua comandă v și ieșirea y .

Pentru sistemele *Single-Input Single-Output (SISO)*, Boufadene explică în lucrare că metoda presupune derivarea succesivă a ieșirii până când apare în mod explicit intrarea, numărul de derivări necesare definind gradul relativ al sistemului. În această etapă se prezintă și *derivatele Lie* ale ieșirii în raport cu câmpurile vectoriale ale sistemului, iar apoi, se arată că pentru a obține o relație liniară între noua intrare numită intrare virtuală și ieșirea sistemului, este necesar ca termenul prin care intrarea apare în derivata de ordin corespunzător să fie nenul. Din această parte a cărții sunt preluate noțiunile de derivată Lie, grad relativ și lanț de integratoare, utilizate ulterior.

Pentru sistemele *Multi-Input Multi-Output (MIMO)*, procedura devine mai complexă, deoarece fiecărei ieșiri îi corespunde un grad relativ propriu, iar prin derivarea succesivă a ieșirilor se obține o matrice de decuplare, matrice care arată modul în care intrările influențează derivatele ieșirilor. Din [3], s-a extras și ideea că liniarizarea MIMO poate fi aplicată direct numai dacă matricea de decuplare este nesară.

Tot din cartea lui Boufadene s-a preluat ideea că, în cazul sistemelor SISO, gradul relativ complet implică faptul că acesta este egal cu numărul de stări ale sistemului, iar

pentru cazul MIMO, este necesar ca suma gradelor relative ale tuturor ieșirilor să fie egală cu ordinul sistemului. Dacă această condiție este satisfăcută, întreaga dinamică este inclusă în procesul de liniarizare (liniarizare completă), iar în caz contrar, rămâne o dinamică internă ce necesită o analiză separată (liniarizare parțială).

În lucrarea de față sunt tratate exclusiv sisteme cu grad relativ complet, accentul fiind pus pe liniarizarea totală și nu pe analiza dinamicii interne reziduale. În primă fază, metoda este aplicată pe modelul matematic, caz în care funcțiile $f(x)$, $g(x)$ și $h(x)$ sunt cunoscute, iar pașii clasici pot fi urmați atât analitic, cât și în mediul MATLAB. În acest mod, partea bazată pe model are rolul de a valida pașii de calcul, iar aceste noțiuni introductive pregătesc trecerea către următoarele secțiuni, unde elementele necesare liniarizării nu mai sunt calculate direct din model, ci sunt identificate folosind date generate de sistem.

2.2 De la model cunoscut la abordarea bazată pe date

În literatura clasică de control neliniar, liniarizarea prin reacție de la stare este realizată pornind de la un model matematic cunoscut al sistemului, ipoteză care permite calcularea directă a derivatelor Lie, a gradului relativ, a matricei de decuplare și a legii de control. În aplicațiile reale, sistemul poate conține neliniarități complexe sau parametri greu de determinat experimental, obținerea unui model precis fiind dificilă. În [8] se subliniază această limitare, dar și faptul că liniarizarea exactă prin reacție se bazează pe cunoașterea precisă a modelului și a parametrilor din sistem. Această constrângere a motivat dezvoltarea metodelor de control bazate pe date, care utilizează măsurători experimentale pentru a extrage informația necesară controlului, fără construirea explicită a unui model complet [9].

În lucrarea [10] se evidențiază distincția esențială dintre abordarea directă și cea indirectă: metodele indirecte utilizează datele pentru identificarea unui model, pe baza căruia se proiectează ulterior regulatorul, iar metodele directe nu au nevoie de acest pas intermediar, ci au ca scop determinarea unei soluții de control compatibilă cu datele, astfel se demonstrează că datele pot fi valorificate nu doar în scop de modelare. În literatură se subliniază că metodele bazate pe date nu trebuie privite ca o simplă înlocuire a modelării, ci trebuie avut în vedere că datele măsurate conțin informație despre comportamentul sistemului, însă aceasta trebuie extrasă printr-o formulare corectă a problemei de control.

În cazul sistemelor neliniare, utilizarea datelor poate crea dificultăți suplimentare față de cazul sistemelor liniare, deoarece, după cum este prezentat și în lucrarea [11], nu este suficientă prezența unor intrări persistent excitante sau simpla colectare a unui volum extins de date, calitatea și conținutul acestora fiind aspecte extrem de importante. Așadar, tranziția de la metodele bazate pe model la cele bazate pe date scoate în lumină alte dificultăți: în locul construirii unui model matematic complet, atenția se mută pe calitatea datelor și pe formularea unui cadru numeric adecvat, perspectivă care pregătește următoarele direcții.

2.3 Rolul dicționarilor de funcții în metodele data-driven

În multe metode moderne de identificare și control bazat pe date, funcțiile neliniare sunt reprezentate cu ajutorul unui set de funcții candidate, numit dicționar sau bibliotecă. Acest dicționar poate conține termeni polinomiali, funcții trigonometrice, funcții raționale sau alte expresii alese în funcție de structura sistemului. Ideea centrală este că, în loc să se caute o funcție complet necunoscută, se caută o combinație de termeni din setul ales anterior.

O lucrare relevantă în această direcție este [12], în care Brunton, Proctor și Kutz propun metoda SINDy (Sparse Identification of Nonlinear Dynamical Systems), autorii plecând de la observația că multe sisteme pot fi descrise printr-un număr redus de termeni relevanți, selectați dintr-o bibliotecă mai mare de funcții candidate. Practic, se construiește o bibliotecă de funcții, iar apoi se folosește regresie rară pentru a identifica termenii importanți, idee care arată relevanța dicționarului în obținerea unei reprezentări compacte a unui sistem neliniar.

În controlul bazat pe date pentru sisteme neliniare, alegerea funcțiilor de bază nu se limitează doar la identificarea modelului, ci apare și în formulări orientate direct spre proiectarea regulatorului. În [13], Dai și Sznaier consideră cazul în care dinamica necunoscută poate fi parametrizată cu ajutorul unui set cunoscut de funcții de bază și formulează o problemă de sinteză a unui regulator stabilizator pe baza unor date experimentale cu zgomot mărginit. Lucrarea aceasta arată că dicționarul nu este important doar pentru partea de identificare, ci și pentru proiectarea directă a controlului.

O problemă delicată rămâne însă alegerea acestui dicționar. În lucrarea [14], Guo, De Persis și Tesi scot în evidență că pentru sistemele neliniare, funcțiile de bază care descriu dinamica sunt esențiale și că acestea sunt alese, de obicei, folosind informații anterioare despre sistem. În cazul în care nu există acces la aceste informații, autorii propun folosirea dezvoltării Taylor, astfel încât sistemul să poată fi aproximat local prin termeni polinomiali. Acest aspect este important și pentru metoda liniarizării prin reacție de la stare bazată pe date. În lucrarea [4], se folosesc dicționare de funcții candidate pentru a reprezenta transformarea de coordonate și termenii de feedback și se observă că alegerea bibliotecii este importantă: pe date fără zgomot se poate utiliza un dicționar mai bogat, însă în prezența zgomotului poate conduce la supraînvățare și selecția unor termeni nerelevanți.

Așadar, în abordările data-driven pentru sisteme neliniare, dicționarele de funcții reprezintă un element central, calitatea rezultatelor depinzând direct de alegerea acestora: un dicționar ales adecvat conduce la soluții precise, în timp ce absența termenilor relevanți duce la obținerea unei soluții care poate fi doar aproximativă.

2.4 Liniarizarea prin reacție de la stare din perspectiva datelor

În controlul neliniar, literatura recentă prezintă o direcție importantă și anume extinderea liniarizării prin reacție de la stare către situații în care modelul matematic al sis-

temului nu este cunoscut în mod explicit. În forma clasică, metoda presupune cunoașterea funcțiilor care descriu dinamica sistemului, pe baza acestora determinându-se transformarea de coordonate și legea de control. În abordarea bazată pe date, se urmărește obținerea acestor elemente din traiectoriile măsurate ale sistemului, astfel că datele nu sunt folosite neapărat pentru identificarea sistemului, ci pentru determinarea unor elemente necesare liniarizării și proiectării controlului.

Lucrarea centrală pentru această direcție este [4], lucrare în care se tratează problema liniarizării prin reacție de la stare pentru sisteme neliniare necunoscute. Autorii propun o metodă prin care să se obțină transformarea de coordonate și regulatorul liniarizant din date experimentale, utilizând un set de funcții candidate. Lucrarea este importantă deoarece păstrează ideea de bază a liniarizării prin reacție, doar că o reformulează într-un cadru data-driven. Tot în această lucrare, autorii abordează problema într-un mod algebric și arată că se poate construi o matrice de date, iar soluția este căutată în spațiul nul al acesteia, funcțiile necesare liniarizării fiind reprezentate prin combinații ale funcțiilor candidate. Această lucrare este referința principală pentru trecerea de la liniarizarea clasică, în care modelul matematic este cunoscut, la abordarea bazată pe date și stă la baza dezvoltărilor care sunt prezentate în capitolul următor. În aceeași lucrare, accentul este pus pe cazul în care datele nu prezintă zgomot, dar se menționează că, atunci când datele sunt zgomotoase, apare o dificultate care necesită o analiză suplimentară: pentru construirea matricei de date este nevoie de derivate ale stărilor, aspect care poate produce instabilitate numerică.

O altă lucrare apropiată de această direcție este [15], unde este analizat controlul bazat pe date pentru sisteme neliniare liniarizabile prin feedback. Autorii extind idei din teoria comportamentală către sisteme neliniare și arată că, în anumite condiții, traiectoriile sistemului pot fi reprezentate direct folosind date. Această lucrare este relevantă pentru contextul temei, deoarece confirmă interesul actual pentru metode care exploatează proprietatea de liniarizabilitate prin feedback fără a porni neapărat de la un model complet cunoscut.

Câteva lucrări care arată că problema liniarizării fără a cunoaște modelul este activă în literatura recentă sunt [16], [17] și [18]. În [18], Fraile, Marchi și Tabuada studiază sistemele SISO și arată că unele idei de control pot fi formulate direct pe baza datelor măsurate, fără a fi nevoie de pasul intermediar de identificare, însă evidențiază și faptul că metodele care folosesc derivate estimate din semnale măsurate, de cele mai multe ori, sunt sensibile la zgomot. În lucrarea [16], Umlauft și Hirche propun o metodă de liniarizare prin reacție care se bazează pe procese gaussiene, o abordare interesantă care, spre deosebire de cea algebrică, folosește un model probabilistic al dinamicii și îl actualizează online în funcție de incertitudinea estimată. Este o lucrare relevantă pentru contextul acestei teme deoarece arată că liniarizarea prin reacție fără model matematic explicit poate fi tratată și prin metode de învățare. O altă perspectivă este cea oferită de lucrarea [17], unde Westenbroek propune folosirea unor tehnici de optimizare fără model pentru a învăța un regulator liniarizant atunci când nu este disponibilă dinamica sistemului.

În ansamblu, literatura recentă arată că liniarizarea prin reacție bazată pe date este

2.5. INFLUENȚA DATELOR ZGOMOTOASE ÎN CONTROLUL BAZAT PE DATE²¹

un subiect actual, iar dintre toate lucrările analizate, articolul [4] reprezintă reperul principal pentru această lucrare, deoarece păstrează structura clasică și propune identificarea directă a elementelor necesare din setul de date. Celelalte abordări completează contextul bibliografic și arată că aceeași problemă poate fi tratată prin metode diferite, precum metode de învățare, metode probabilistice sau metode de stabilizare directă. Aceste direcții au însă dificultăți comune, legate de alegerea adecvată a funcțiilor din bibliotecă, calitatea datelor măsurate, estimarea derivatelor și sensibilitatea la zgomot.

2.5 Influența datelor zgomotoase în controlul bazat pe date

În multe lucrări despre controlul bazat pe date, rezultatele teoretice sunt prezentate inițial sub ipoteza unor date ideale, fără zgomot. Aceasta este o ipoteză utilă pentru că formulează clar metoda, însă în realitate datele colectate nu sunt perfecte, deoarece intervine zgomotul provenit de la senzori, perturbații externe sau erori de achiziție, astfel că dificultatea nu constă doar în proiectarea legii de control, ci se mută și pe modul în care zgomotul din date influențează rezultatele obținute. În cazul sistemelor neliniare, efectul acestor erori este important deoarece datele nu sunt folosite doar ca valori măsurate, ci au rol în evaluarea unor funcții neliniare, în estimarea derivatelor și în construirea matricelor necesare.

Acest aspect apare în lucrarea principală [4], unde se scoate în evidență că metoda folosește derivate ale stării, iar în cazul datelor zgomotoase, estimarea acestor derivate produce instabilitate numerică. Drept posibile direcții de rezolvare a acestei probleme, autorii sugerează filtrarea sau abordarea unei formulări integrale, observație care este un punct important al acestei lucrări.

În articolul [19], Chang și Bernstein arată că datele zgomotoase produc erori în reprezentarea sistemului, iar acestea se transmit ulterior în proiectarea controlului, tratând explicit problema proiectării controlului folosind date de intrare-ieșire cu zgomot. Este o lucrare relevantă deoarece arată faptul că zgomotul nu este doar o simplă problemă de măsurare, ci afectează direct reprezentarea construită din date. În cazul liniarizării prin reacție de la stare bazată pe date, o mică perturbare a stărilor poate schimba valorile funcțiilor din dicționar, derivatele estimate și, totodată, spațiul nul folosit la identificare, astfel că zgomotul nu afectează doar semnalul măsurat, ci și obiectele construite din date, de exemplu, matricile folosite în calcul. De asemenea, în lucrarea [20] apare o perspectivă apropiată, lucrare unde se studiază stabilizarea directă a unei clase de sisteme neliniare și unde se evidențiază că perturbațiile din date trebuie incluse în formularea problemei, și nu tratate doar ca un efect secundar. Pentru lucrarea de față, acest lucru motivează separarea cazului ideal, fără zgomot, de cazul în care stările măsurate sunt zgomotoase, cele două situații conducând la rezultate numerice diferite.

Un alt aspect important care se prezintă în articolul [21] este că, în prezența unor măsurători zgomotoase, nu se mai poate considera că datele descriu un sistem exact, unic, ci mai degrabă se poate considera că există o mulțime de sisteme compatibile cu măsurătorile

și informațiile disponibile. Aceasta este o idee utilă în cadrul acestei teme deoarece schimbă perspectiva din care este privită identificarea: nu se caută o soluție exactă în cazul datelor cu zgomot, ci se caută o soluție suficient de bună și stabilă numeric, iar pentru metoda analizată acest lucru înseamnă că soluțiile obținute nu trebuie validate doar prin eroarea de identificare, ci trebuie evaluat și comportamentul sistemului în buclă închisă.

În cazul liniarizării prin reacție de la stare bazată pe date, zgomotul aduce probleme din două motive: primul motiv este estimarea derivatelor deoarece derivarea numerică amplifică variațiile rapide din sistem, iar al doilea motiv vizează construcția matricei de date: dacă stările și derivatele sunt afectate de erori, atunci și matricea folosită pentru identificare poate fi slab condiționată sau poate prezenta un spațiu nul diferit de cazul ideal. Din acest motiv, validarea soluțiilor trebuie făcută cu atenție, deoarece o soluție poate să pară acceptabilă din punct de vedere al unei erori algebrice, dar să aibă un comportament nesatisfăcător în buclă închisă. În cazul controlului, scopul nu este doar identificarea unor coeficienți, ci obținerea unei legi de comandă care să stabilizeze sistemul, să mențină stările într-o evoluție controlată și să mențină semnalul de comandă într-un domeniu rezonabil, observație care face legătura cu partea aplicativă a acestei lucrări, unde soluțiile obținute sunt verificate prin simulări, nu doar prin indicatori numerici ai identificării.

Așadar, literatura actuală arată că datele afectate de zgomot aduc principalele dificultăți ale metodelor data-driven, în această lucrare, cazul fără zgomot fiind folosit ca punct de reper, iar introducerea zgomotului permițând testarea metodei într-o situație mai apropiată de aplicațiile reale. Pentru a diminua efectul zgomotului, sunt necesare metode suplimentare, cum ar fi filtrarea semnalului, regularizarea și metode de identificare mai robuste numeric, direcții care sunt prezentate în următorul subcapitol.

2.6 Metode numerice de reducere a efectului zgomotului

După introducerea zgomotului în date, partea de identificare nu mai depinde strict de formularea teoretică a metodei, ci și de stabilitatea numerică a calculelor și de modul de prelucrare a semnalelor măsurate. În cadrul liniarizării prin reacție de la stare din perspectivă data-driven, matricele utilizate la identificare sunt construite direct din valorile stărilor, din derivatele estimate numeric și din valorile funcțiilor evaluate în dicționar. În cazul ideal, atunci când se folosesc date fără zgomot, se obține o soluție clară în spațiul nul al matricei, însă în prezența zgomotului identificarea devine o problemă sensibilă numeric. Erorile din date se transmit în toate mărimile enumerate anterior, motiv pentru care apare nevoia folosirii unor metode de filtrare și regularizare care să reducă influența zgomotului asupra soluțiilor obținute.

În lucrarea [4] autorii menționează că studiul robusteții metodei la date zgometoase reprezintă o direcție practică importantă și sugerează două posibilități de abordare: filtrarea datelor și folosirea unor tehnici de integrare pentru reducerea efectului zgomotului. În lucrarea de față, aceste sugestii sunt adaptate numeric prin filtrarea semnalelor de stare

și prin folosirea unei forme integrale a relației de identificare, astfel se modifică modul în care relația folosită pentru identificare este construită din date.

Un prim aspect important este filtrarea semnalelor înainte de estimarea derivatelor. În articolul [22], Schafer definește filtrul Savitzky-Golay ca o metodă de netezire a semnalului bazată pe o aproximare locală a datelor cu ajutorul unui polinom în sensul celor mai mici pătrate, abordare care este utilă deoarece ajută la reducerea oscilațiilor rapide produse de zgomot, însă păstrează suficient de bine forma locală a semnalului. În metodele în care apare necesitatea derivatelor estimate numeric, partea de filtrare nu poate fi neglijată, deoarece derivarea amplifică zgomotul prezent în date, iar de multe ori, o derivată calculată direct din date zgomotoase poate fi mult mai imprecisă decât semnalul inițial, din acest motiv, filtrarea înainte de derivare este o etapă esențială când există date perturbate [23].

Următorul aspect important în reducerea efectului provocat de zgomot constă în folosirea unei forme integrale a relației de identificare, idee preluată tot din lucrarea [4], unde autorii menționează tehnicile de integrare ca posibilă modalitate de filtrare a zgomotului în controlul bazat pe date. Această abordare presupune că, în loc să se folosească direct forma diferențială a relației de liniarizare, ea se poate integra pe intervale de timp, astfel, identificarea nu mai depinde direct de derivata punctuală a stării. În lucrarea de față, această idee este adaptată pentru construirea unei matrici de identificare în forma integrală atunci când datele sunt afectate de zgomot.

A treia direcție folosită pentru stabilizarea identificării este regularizarea. În cazul ideal, fără zgomot, coeficienții căutați sunt determinați prin anularea unei relații construite din date, însă în practică zgomotul și erorile numerice fac ca această relație să nu mai poată fi satisfăcută exact. Din acest motiv, regularizarea Tikhonov introduce o penalizare asupra coeficienților, reducând tendința soluției de a urmări zgomotul din date și conducând la o problemă numerică mai bine condiționată [24]. De asemenea, analiza spațiului nul, a valorilor singulare și a condiționării matricelor se bazează pe instrumente numerice standard, precum descompunerea SVD, prezentată pe larg în lucrările de calcul matriceal [25]. În [10] se arată că regularizările au un rol important în controlul bazat pe date și pot fi interpretate ca o formă de identificare implicită în metodele directe. Totodată, lucrarea [19] justifică folosirea regularizării și verificarea atentă a soluțiilor obținute, mai ales atunci când matricele de identificare sunt construite din date măsurate afectate de zgomot.

Prin urmare, metodele numerice pentru reducerea efectului provocat de zgomot reprezintă o completare necesară într-o abordare bazată pe date, deoarece permit trecerea de la cazul ideal, cu date neperturbate, la cazul mai realist, în care se folosesc date zgomotoase și în care soluțiile trebuie alese cu atenție. Astfel, filtrarea, forma integrală și regularizarea devin instrumente utile atât pentru identificarea coeficienților, cât și pentru validarea metodei de control în prezența zgomotului.

Capitolul 3

Analiză, Proiectare și Implementare

3.1 Analiză și Fundamentare Teoretică

3.1.1 Formularea problemei și liniarizarea clasică prin reacție de la stare

Lucrarea pornește de la problema controlului sistemelor neliniare continue afine în intrare, sisteme la care comanda apare liniar în ecuațiile de stare. Această clasă de sisteme se poate scrie sub forma generală:

$$\dot{x} = f(x) + g(x)u, \quad (3.1)$$

unde $x \in \mathbb{R}^n$ reprezintă vectorul de stare, n fiind ordinul sistemului, $u \in \mathbb{R}^m$ este vectorul de comandă, iar m reprezintă numărul de intrări. Funcțiile $f(x)$ și $g(x)$ descriu dinamica proprie a sistemului și modul în care stările sunt influențate de intrare. Dacă se consideră că sistemul are și o ieșire măsurabilă, aceasta se notează prin:

$$y = h(x), \quad (3.2)$$

unde y este ieșirea sistemului, iar $h(x)$ este funcția de ieșire.

Reprezentarea (3.1) constituie punctul de pornire pentru una dintre metodele consacrate de control neliniar: liniarizarea prin reacție de la stare. În formularea sa clasică, metoda urmărește determinarea unei legi de comandă care transformă sistemul neliniar într-un sistem echivalent liniar, acesta fiind mai simplu de analizat și controlat, deoarece există numeroase metode cunoscute de proiectare în teoria sistemelor liniare [3]. Pentru sistemele neliniare de această formă, în cartea lui Boufaden sunt prezentați pașii metodei și scopul final al acesteia: obținerea unei relații liniare între o intrare auxiliară și ieșirea sistemului.

Ideea principală a liniarizării prin reacție de la stare este separarea comenzii reale aplicate sistemului de dinamica liniară dorită. În acest scop, se introduce o nouă mărime de comandă, numită intrare auxiliară sau intrare virtuală, notată în continuare cu ν . Comanda reală este notată cu u și nu mai este aleasă în mod direct, ci este determinată

astfel încât să compenseze neliniaritățile din sistem și să conducă la o dinamică liniară echivalentă. Prin urmare, proiectarea regulatorului se realizează în două etape. În prima etapă se determină transformarea neliniară de coordonate și legea de compensare care aduce sistemul într-o formă liniară. În a doua etapă se proiectează regulatorul liniar pentru sistemul rezultat, astfel încât dinamica în buclă închisă să fie stabilă.

Pentru prezentarea metodei se consideră mai întâi un sistem cu o singură intrare și o singură ieșire, de forma (3.1), având ieșirea (3.2). Acesta corespunde cazului SISO, în care atât intrarea u , cât și ieșirea y , sunt mărimi scalare.

Într-o primă etapă, pentru a evidenția modul în care intrarea influențează evoluția ieșirii, se derivează ieșirea y în raport cu timpul:

$$\dot{y} = \frac{\partial h}{\partial x} \dot{x}. \quad (3.3)$$

Înlocuind dinamica sistemului din relația (3.1) în relația (3.3), se obține:

$$\dot{y} = \frac{\partial h}{\partial x} [f(x) + g(x)u]. \quad (3.4)$$

Prin separarea termenilor, relația (3.4) devine:

$$\dot{y} = \frac{\partial h}{\partial x} f(x) + \frac{\partial h}{\partial x} g(x)u. \quad (3.5)$$

Expresia (3.5) se poate scrie mai compact folosind notația derivatelor Lie ale lui h de-a lungul câmpurilor vectoriale f și g :

$$\dot{y} = L_f h(x) + L_g h(x) u, \quad (3.6)$$

unde:

$$L_f h(x) = \frac{\partial h}{\partial x} f(x), \quad L_g h(x) = \frac{\partial h}{\partial x} g(x). \quad (3.7)$$

Dacă termenul $L_g h(x)$ este nenul, atunci intrarea apare deja în prima derivată a ieșirii. În caz contrar, dacă acest termen este zero, se continuă derivarea ieșirii până când intrarea u apare explicit. Astfel apare noțiunea de grad relativ al sistemului, definit ca ordinul primei derivate a ieșirii în care apare comanda.

Un sistem SISO are grad relativ r dacă intrarea nu apare în primele $r - 1$ derivate ale ieșirii, ci apare în derivata de ordin r . Aici, r reprezintă numărul de derivări necesare până când intrarea influențează explicit ieșirea. Proprietatea aceasta se poate exprima prin relațiile:

$$L_g L_f^k h(x) = 0, \quad k = 0, 1, \dots, r - 2, \quad (3.8)$$

și:

$$L_g L_f^{r-1} h(x) \neq 0. \quad (3.9)$$

În aceste condiții, derivata de ordin r a ieșirii este:

$$y^{(r)} = L_f^r h(x) + L_g L_f^{r-1} h(x) u. \quad (3.10)$$

Relația (3.10) se poate rescrie sub formă simplificată introducând notațiile $\delta(x)$ și $\gamma(x)$:

$$y^{(r)} = \delta(x) + \gamma(x) u. \quad (3.11)$$

unde:

$$\delta(x) = L_f^r h(x), \quad \gamma(x) = L_g L_f^{r-1} h(x). \quad (3.12)$$

În relația (3.11), $\delta(x)$ grupează termenii neliniari care nu depind direct de comandă, iar $\gamma(x)$ descrie modul în care intrarea u influențează derivata de ordin r a ieșirii. Forma obținută sugerează cheia metodei: dacă $\gamma(x)$ este diferit de zero într-o regiune de interes, se poate alege comanda u astfel:

$$u = \frac{1}{\gamma(x)} [-\delta(x) + \nu], \quad (3.13)$$

unde ν este noua intrare a sistemului. Înlocuind comanda (3.13) în relația (3.11), se obține:

$$y^{(r)} = \delta(x) + \gamma(x) \cdot \frac{1}{\gamma(x)} [-\delta(x) + \nu] = \delta(x) - \delta(x) + \nu = \nu. \quad (3.14)$$

Rezultă, după simplificări:

$$y^{(r)} = \nu. \quad (3.15)$$

Astfel, la nivel intrare-ieșire, sistemul neliniar este transformat într-un lanț de integratoare, formă esențială a liniarizării prin reacție de la stare pentru cazul SISO [3].

Un aspect important apare atunci când gradul relativ este egal cu ordinul sistemului, adică $r = n$, caz în care sistemul admite o liniarizare exactă la nivelul stării, respectiv are grad relativ complet. Dacă $r < n$, apare noțiunea de liniarizare parțială, deoarece în sistem persistă dinamici interne care nu sunt incluse în relația intrare-ieșire obținută prin derivarea ieșirii. Pentru această lucrare este important cazul cu grad relativ complet, deoarece permite descrierea întregii dinamici a sistemului în coordonate noi, ipoteză care se păstrează și în abordarea bazată pe date, discutată ulterior.

Pentru cazul SISO cu grad relativ complet, transformarea de coordonate se poate scrie sub forma:

$$\tau(x) = \begin{bmatrix} h(x) \\ L_f h(x) \\ \vdots \\ L_f^{n-1} h(x) \end{bmatrix}. \quad (3.16)$$

Funcția $\tau(x)$ din relația (3.16) definește noile coordonate ale sistemului. Dacă Jacobianul acestei transformări este nesingular în regiunea analizată, atunci $\tau(x)$ definește local o

schimbare validă de coordonate. În aceste coordonate, sistemul poate fi adus într-o formă liniară de tip lanț de integratoare, iar intrarea virtuală ν poate fi aleasă ulterior prin metode de control liniar.

În cazul sistemelor MIMO pătratice, cu același număr de intrări și ieșiri, mersul metodei este similar cu cel din cazul SISO, dar relațiile se scriu vectorial. Se consideră un astfel de sistem:

$$\dot{x} = f(x) + \sum_{i=1}^m g_i(x) u_i, \quad (3.17)$$

având ieșirile:

$$y_1 = h_1(x), \quad y_2 = h_2(x), \quad \dots, \quad y_m = h_m(x). \quad (3.18)$$

În relația (3.17), m reprezintă numărul de intrări, u_i este componenta i a vectorului de comandă, iar $g_i(x)$ este câmpul vectorial asociat acestei intrări. În cazul MIMO, fiecărei ieșiri y_i i se asociază un grad relativ r_i . Numărul r_i arată de câte ori trebuie derivată ieșirea y_i până când intrările sistemului apar explicit. După derivarea acestor ieșiri până la ordinul corespunzător, se obține:

$$\begin{pmatrix} y_1^{(r_1)} \\ y_2^{(r_2)} \\ \vdots \\ y_m^{(r_m)} \end{pmatrix} = A(x) + D(x) u, \quad (3.19)$$

unde $A(x)$ conține termenii neliniari care nu depind direct de intrare, iar $D(x)$ reprezintă matricea de decuplare. Mai exact, componentele lui $A(x)$ sunt de forma:

$$A_i(x) = L_f^{r_i} h_i(x), \quad (3.20)$$

iar elementele matricei de decuplare sunt:

$$D_{ij}(x) = L_{g_j} L_f^{r_i-1} h_i(x), \quad i, j = 1, \dots, m. \quad (3.21)$$

Matricea $D(x)$ arată modul în care fiecare intrare influențează derivatele de ordin corespunzător ale ieșirilor. Liniarizarea prin reacție este posibilă local dacă matricea de decuplare $D(x)$ este inversabilă în regiunea de interes [3]. Comanda este aleasă astfel:

$$u = D(x)^{-1} [-A(x) + \nu], \quad (3.22)$$

unde $\nu \in \mathbb{R}^m$ este vectorul intrărilor virtuale. Înlocuind comanda (3.22) în relația (3.19), se obține:

$$\begin{pmatrix} y_1^{(r_1)} \\ y_2^{(r_2)} \\ \vdots \\ y_m^{(r_m)} \end{pmatrix} = A(x) + D(x) D(x)^{-1} [-A(x) + \nu]. \quad (3.23)$$

Deoarece $D(x)$ este inversabilă, relația (3.23) devine:

$$\begin{pmatrix} y_1^{(r_1)} \\ y_2^{(r_2)} \\ \vdots \\ y_m^{(r_m)} \end{pmatrix} = A(x) - A(x) + \nu. \quad (3.24)$$

Prin urmare:

$$\begin{pmatrix} y_1^{(r_1)} \\ y_2^{(r_2)} \\ \vdots \\ y_m^{(r_m)} \end{pmatrix} = \nu. \quad (3.25)$$

Astfel, relația dintre intrarea nouă ν și ieșirile derivate devine liniară.

Pentru aceste sisteme, condiția de grad relativ complet se exprimă prin:

$$r_1 + r_2 + \cdots + r_m = n, \quad (3.26)$$

astfel încât nu rămân dinamici interne neincluse în transformarea de coordonate, iar transformarea de coordonate include toate stările sistemului.

Pentru cazul MIMO cu grad relativ complet, transformarea de coordonate se construiește prin gruparea ieșirilor și a derivatelor Lie ale acestora:

$$\tau(x) = \begin{bmatrix} h_1(x) \\ L_f h_1(x) \\ \vdots \\ L_f^{r_1-1} h_1(x) \\ h_2(x) \\ L_f h_2(x) \\ \vdots \\ L_f^{r_2-1} h_2(x) \\ \vdots \\ h_m(x) \\ L_f h_m(x) \\ \vdots \\ L_f^{r_m-1} h_m(x) \end{bmatrix}. \quad (3.27)$$

Dacă Jacobianul transformării (3.27) este nesingular în regiunea analizată, atunci $\tau(x)$ definește local o schimbare validă de coordonate. În aceste coordonate, sistemul poate fi scris într-o formă liniară de tip Brunovsky, alcătuită din lanțuri de integratoare asociate fiecărei ieșiri.

În această lucrare, noțiunile prezentate mai sus sunt folosite ca punct de pornire, însă nu se urmărește doar aplicarea metodei clasice. În metoda de bază se presupune cunoașterea explicită a modelului matematic, ceea ce înseamnă că funcțiile $f(x)$, $g(x)$ și eventual $h(x)$ sunt cunoscute. În aplicațiile practice, această condiție nu este mereu îndeplinită: modelul poate fi dificil de identificat, poate conține parametri necunoscuți sau poate fi mult prea complex pentru a fi utilizat direct în proiectarea controlului. Această limitare este importantă deoarece liniarizarea exactă prin reacție de la stare se bazează pe o cunoaștere precisă a modelului și a parametrilor acestuia [8].

Din acest motiv, în lucrare se urmărește o formulare data-driven, care presupune identificarea din date a funcțiilor necesare liniarizării, reducând astfel dependența de modelul analitic. Direcția aceasta este propusă în lucrarea [4], unde, în loc să se pornească de la un model matematic cunoscut, se pornește de la un set de date experimentale, din care se determină elementele necesare liniarizării. Autorii propun identificarea transformării de coordonate și implicit a controlerului liniarizant dintr-o bibliotecă de funcții candidate, folosind o procedură algebrică bazată pe spațiul nul al unei matrice construite din date.

3.1.2 Reformularea problemei din perspectiva data-driven

Abordarea prezentată în continuare pornește de la aceeași idee fundamentală a liniarizării prin reacție de la stare, însă diferă prin modul în care sunt obținute elementele necesare. În acest caz, scopul este de a determina transformarea de coordonate și termenii care apar în legea de control într-un mod direct, fără a determina mai întâi modelul complet al sistemului, adică funcțiile $f(x)$ și $g(x)$. În lucrarea de bază [4], problema este formulată pentru un sistem necunoscut, dar pentru care sunt disponibile date experimentale. Autorii urmăresc determinarea elementelor necesare liniarizării dintr-o bibliotecă de funcții candidate, printr-o procedură algebrică bazată pe o matrice care înglobează datele experimentale disponibile.

Se consideră același sistem neliniar afin în intrare ca în subcapitolul anterior, de forma (3.1). În abordarea clasică, prezentată anterior, scopul era determinarea unei transformări de coordonate și a unei legi de control care să aducă sistemul neliniar într-o formă liniară, mai ușor de analizat și controlat. În formularea bazată pe date, scopul rămâne același, însă nu se presupune accesul explicit la funcțiile $f(x)$ și $g(x)$. În schimb, sunt disponibile date care descriu evoluția sistemului pentru diferite valori ale stării și ale intrării, colectate din experimente realizate pe sistem.

Ideea principală constă în introducerea unei transformări de coordonate:

$$\eta = \tau(x), \quad (3.28)$$

unde $\tau: D \rightarrow \mathbb{R}^n$ este o schimbare de coordonate validă într-o regiune D a spațiului stărilor. Pentru ca această transformare să fie utilă din punct de vedere al controlului, ea trebuie să fie local inversabilă, astfel încât stabilizarea în coordonatele η să corespundă stabilizării sistemului inițial în coordonatele x . În lucrarea de referință, această transformare este

definită ca un difeomorfism local, iar o condiție suficientă pentru validitatea locală este nesingularitatea Jacobianului transformării în regiunea analizată [4].

Prin derivarea noilor coordonate din relația (3.28) în raport cu timpul și prin înlocuirea dinamicii sistemului (3.1), se obține:

$$\dot{\eta} = \frac{\partial \tau}{\partial x} \dot{x} = \frac{\partial \tau}{\partial x} [f(x) + g(x)u]. \quad (3.29)$$

Pentru a se putea realiza liniarizarea prin reacție, scopul este de a aduce relația (3.29) la o formă liniară canonică. În lucrarea de referință, condiția fundamentală este existența a trei funcții $\tau(x)$, $\delta(x)$ și $\gamma(x)$, astfel încât:

$$\frac{\partial \tau}{\partial x} (f(x) + g(x)u) = A_c \tau(x) + B_c (\delta(x) + \gamma(x)u). \quad (3.30)$$

Relația (3.30) reprezintă baza metodei folosite. Aceasta exprimă faptul că dinamica sistemului în noile coordonate este împărțită în două componente: o parte liniară, impusă prin matricele A_c și B_c , și o parte asociată neliniarităților și influenței intrării, grupată în termenii $\delta(x)$ și $\gamma(x)$. Reformularea este utilă deoarece dinamica $f(x) + g(x)u$ poate fi înlocuită ulterior prin datele măsurate, fără a cunoaște separat funcțiile $f(x)$ și $g(x)$.

Matricele A_c și B_c descriu forma liniară dorită, de tip Brunovsky. Pentru un sistem cu m canale intrare-ieșire, acestea au structură bloc-diagonală:

$$A_c = \text{blkdiag}(A_1, A_2, \dots, A_m), \quad B_c = \text{blkdiag}(B_1, B_2, \dots, B_m), \quad (3.31)$$

unde fiecare pereche (A_i, B_i) corespunde unui lanț de integratoare de ordin r_i . Concret, pentru canalul i :

$$A_i = \begin{pmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \\ 0 & 0 & 0 & \cdots & 0 \end{pmatrix} \in \mathbb{R}^{r_i \times r_i}, \quad B_i = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{pmatrix} \in \mathbb{R}^{r_i \times 1}. \quad (3.32)$$

Ordinele $r_1, r_2, \dots, r_m$ satisfac condiția de grad relativ complet (3.26). Această condiție arată că întreaga dinamică a sistemului este inclusă în noile coordonate, fără apariția unor dinamici interne neincluse în transformarea de coordonate.

Cele trei funcții care apar în relația de liniarizare (3.30) au roluri diferite:

- funcția $\tau(x)$ definește noile coordonate în care sistemul capătă o formă liniară;
- funcția $\delta(x)$ înglobează partea neliniară care trebuie compensată;
- funcția $\gamma(x)$ definește modul în care intrarea u influențează dinamica în coordonatele transformate.

O condiție importantă este legată de termenul $\gamma(x)$, care trebuie să fie inversabil în zona de interes. În cazul sistemelor SISO, aceasta înseamnă că $\gamma(x)$ este un scalar nenul, iar în cazul sistemelor MIMO, $\gamma(x)$ trebuie să fie o matrice nesingulară.

Dacă se introduce notația:

$$\nu = \delta(x) + \gamma(x)u, \quad (3.33)$$

relația fundamentală (3.30) determină forma liniară intermediară:

$$\dot{\eta} = A_c \eta + B_c \nu. \quad (3.34)$$

În acest caz, dacă perechea (A_c, B_c) este controlabilă, se poate determina o lege liniară de control de forma:

$$\nu = K\eta, \quad (3.35)$$

unde K este o matrice de câștig aleasă astfel încât $A_c + B_c K$ să fie Hurwitz. Revenind la variabilele originale, prin înlocuirile (3.35) și (3.28), se obține:

$$\delta(x) + \gamma(x)u = K\tau(x). \quad (3.36)$$

Dacă $\gamma(x)$ este inversabilă pe regiunea de interes, din relația (3.36) rezultă legea de control aplicată sistemului original:

$$u = \gamma(x)^{-1} [K\tau(x) - \delta(x)]. \quad (3.37)$$

Înlocuind comanda (3.37) în dinamica transformată (3.34), se obține:

$$\dot{\eta} = (A_c + B_c K) \eta. \quad (3.38)$$

Relația (3.38) arată că sistemul în coordonatele η este liniar. Dacă K este ales astfel încât $A_c + B_c K$ să fie Hurwitz, atunci sistemul liniar obținut este asimptotic stabil.

Relațiile (3.35)–(3.38) arată că, după identificarea funcțiilor $\tau(x)$, $\delta(x)$ și $\gamma(x)$, problema de control se reduce la proiectarea matricei K . Această etapă este separată de identificarea celor trei funcții și se realizează după obținerea formei liniare a sistemului.

Ideea principală evidențiată în [4] este că, dacă relația de liniarizare (3.30) este respectată, atunci se poate considera o lege de forma (3.35), cu K ales astfel încât $A_c + B_c K$ să fie Hurwitz. În aceste condiții, comanda (3.37) stabilizează sistemul neliniar în jurul punctului de echilibru.

Comparativ cu metoda clasică, structura generală a soluției este aceeași: se caută transformarea $\tau(x)$ și termenii $\delta(x)$, $\gamma(x)$ care să respecte relația de liniarizare (3.30). Diferența apare în modul în care aceste funcții sunt obținute. În abordarea clasică, acestea se calculează din modelul cunoscut, prin derivări Lie repetate și prin utilizarea expresiilor explicite ale câmpurilor vectoriale. În abordarea data-driven, ele sunt considerate necunoscute și sunt identificate din date experimentale, astfel că problema de liniarizare

este transformată într-o problemă de determinare a unor funcții care satisfac relația fundamentală prezentată anterior.

Această observație permite separarea clară a două aspecte diferite. Mai întâi, există o problemă de natură structurală: se presupune că, în zona de interes, există o transformare de coordonate și o lege de feedback capabile să liniarizeze sistemul. Apoi apare problema de identificare: trebuie găsite efectiv funcțiile care realizează această transformare, pornind de la date. În lucrarea de față, accentul cade pe această a doua problemă.

Un aspect care simplifică semnificativ problema este ipoteza absenței zgomotului de măsurare. În acest caz, datele experimentale conțin informații exacte despre stări, intrări și derivatele stărilor, ceea ce permite evaluarea relației de liniarizare:

$$\frac{\partial \tau}{\partial x} \dot{x} = A_c \tau(x) + B_c(\delta(x) + \gamma(x)u) \quad (3.39)$$

în fiecare punct din setul de date disponibil. Relația (3.39) reprezintă forma bazată pe date a relației (3.30), deoarece în locul termenului $f(x) + g(x)u$ apare direct derivata stării $\dot{x}$. Observația importantă este că relația (3.39) implică $\dot{x}$, nu funcțiile $f(x)$ și $g(x)$ separat. Deoarece $\dot{x} = f(x) + g(x)u$, nu mai este necesară cunoașterea explicită a funcțiilor $f(x)$ și $g(x)$, ci este suficientă cunoașterea evoluției sistemului prin date. Această idee justifică trecerea de la abordarea clasică la abordarea data-driven.

Pentru ca soluția obținută din date să fie relevantă nu doar pe punctele măsurate, ci și pe regiunea de interes, datele și dicționarul ales trebuie să fie suficient de informative. Acest aspect este tratat în continuare prin construcția matricei dependente de date și prin analiza spațiului său nul.

Așadar, odată stabilit obiectul identificării, pasul următor este alegerea unei reprezentări potrivite pentru funcțiile necunoscute. În metoda propusă de De Persis, reprezentarea se face printr-un dicționar de funcții candidate, iar coeficienții necunoscuți sunt determinați utilizând o relație algebrică construită pe baza datelor colectate.

3.1.3 Parametrizarea funcțiilor și ecuația de identificare

Anterior, s-a arătat că problema liniarizării poate fi reformulată prin determinarea celor trei funcții $\tau(x)$, $\delta(x)$ și $\gamma(x)$, care definesc transformarea de coordonate, partea neliniară compensată și termenul prin care intrarea apare în dinamica transformată. Deși această reformulare elimină necesitatea de a cunoaște explicit modelul matematic, ea nu este încă rezolvabilă numeric, deoarece căutarea liberă a funcțiilor neliniare rămâne o problemă mult prea generală. În continuare, se prezintă modul în care această problemă este adusă într-o formă algebrică, astfel încât funcțiile necesare liniarizării să poată fi determinate din setul de date disponibil.

Relația fundamentală a liniarizării, scrisă în coordonatele transformate, constituie punctul de plecare. Aceasta este utilă în contextul data-driven deoarece termenul $\dot{x}$ poate fi obținut sau estimat direct din date, fără a fi necesară cunoașterea explicită a funcțiilor

$f(x)$ și $g(x)$:

$$\frac{\partial \tau}{\partial x} \dot{x} = A_c \tau(x) + B_c (\delta(x) + \gamma(x)u). \quad (3.40)$$

Relația (3.40) este forma bazată pe date a relației de liniarizare prezentate anterior, deoarece folosește direct derivata stării $\dot{x}$.

Ca următor pas, în lucrarea [4], autorii introduc funcțiile necunoscute într-o bibliotecă de funcții candidate și transformă condiția de liniarizare într-o relație algebrică cu coeficienți necunoscuți. Pentru a reduce problema la determinarea unui număr finit de parametri, se presupune că funcțiile necunoscute pot fi exprimate ca combinații liniare de funcții candidate cunoscute. Se introduc astfel trei dicționare de funcții:

$$Z : D \rightarrow \mathbb{R}^a, \quad Y : D \rightarrow \mathbb{R}^b, \quad W : D \rightarrow \mathbb{R}^{c \times m}. \quad (3.41)$$

În relația (3.41), D reprezintă domeniul din spațiul stărilor în care se caută transformarea de coordonate și legea de liniarizare, iar a , b și c reprezintă numărul de funcții candidate din fiecare dicționar. Dicționarul Z este folosit pentru reprezentarea transformării de coordonate, Y pentru termenul neliniar, iar W pentru termenul asociat intrării.

Se presupune că există matricile necunoscute de coeficienți T , N și M , astfel încât:

$$\tau(x) = T Z(x), \quad \delta(x) = N Y(x), \quad \gamma(x) = M W(x). \quad (3.42)$$

Dimensiunile acestor matrici sunt alese astfel încât relațiile din (3.42) să fie bine definite:

$$T \in \mathbb{R}^{n \times a}, \quad N \in \mathbb{R}^{m \times b}, \quad M \in \mathbb{R}^{m \times c}. \quad (3.43)$$

Astfel, $\tau(x) \in \mathbb{R}^n$, $\delta(x) \in \mathbb{R}^m$, iar $\gamma(x) \in \mathbb{R}^{m \times m}$. Matricea T conține coeficienții transformării de coordonate, matricea N conține coeficienții termenului neliniar, iar matricea M conține coeficienții termenului $\gamma(x)$. Avantajul principal al acestei substituții este că, în loc să se caute liber forme neliniare necunoscute, problema se reduce la determinarea coeficienților din cele trei matrici, neliniaritățile fiind absorbite în funcțiile alese din dicționare. Un aspect important este faptul că dicționarele pot conține și funcții suplimentare față de cele strict necesare, ceea ce permite folosirea unor biblioteci mai bogate atunci când dinamica sistemului nu este cunoscută cu exactitate.

Mai departe, se înlocuiesc parametrizările (3.42) în relația de liniarizare (3.40). Deoarece matricea T este constantă, rezultă:

$$\frac{\partial(T Z(x))}{\partial x} = T \frac{\partial Z}{\partial x}. \quad (3.44)$$

Prin urmare, relația (3.40) devine:

$$T \frac{\partial Z}{\partial x} \dot{x} = A_c T Z(x) + B_c N Y(x) + B_c M W(x)u. \quad (3.45)$$

Pentru a evidenția caracterul algebric al relației, toți termenii se aduc în aceeași parte:

$$A_c T Z(x) - T \frac{\partial Z}{\partial x} \dot{x} + B_c N Y(x) + B_c M W(x)u = 0. \quad (3.46)$$

Relația (3.46) este neliniară în raport cu starea x , deoarece dicționarele pot conține funcții neliniare, însă este liniară în raport cu coeficienții necunoscuți din T , N și M . Acesta este punctul esențial al metodei: neliniaritatea sistemului este absorbită în funcțiile candidate, în timp ce coeficienții necunoscuți apar liniar. Această relație se poate rescrie într-o formă compactă folosind vectorizarea. Necunoscutele se grupează într-un singur vector al coeficienților:

$$v = \begin{bmatrix} \text{vec}(T) \\ \text{vec}(N) \\ \text{vec}(M) \end{bmatrix}. \quad (3.47)$$

Folosind proprietățile produsului Kronecker, fiecare termen din relația (3.46) se poate rescrie ca o matrice care înmulțește vectorul v . Pentru primul termen se obține:

$$A_c T Z(x) = (Z(x)^\top \otimes A_c) \text{vec}(T). \quad (3.48)$$

Pentru termenul care conține derivata dicționarului $Z(x)$:

$$T \frac{\partial Z}{\partial x} \dot{x} = \left[\left(\frac{\partial Z}{\partial x} \dot{x} \right)^\top \otimes I_n \right] \text{vec}(T), \quad (3.49)$$

unde I_n este matricea identitate de ordin n . Din relațiile (3.48) și (3.49), contribuția termenilor care depind de matricea T se poate scrie:

$$\left[Z(x)^\top \otimes A_c - \left(\frac{\partial Z}{\partial x} \dot{x} \right)^\top \otimes I_n \right] \text{vec}(T). \quad (3.50)$$

Pentru termenul care conține matricea N , se obține:

$$B_c N Y(x) = (Y(x)^\top \otimes B_c) \text{vec}(N). \quad (3.51)$$

În cazul termenului care conține matricea M , se observă mai întâi că $W(x)u$ este un vector dependent de stare și intrare. Astfel:

$$B_c M W(x)u = ((W(x)u)^\top \otimes B_c) \text{vec}(M). \quad (3.52)$$

După acești pași, se definesc următoarele blocuri:

$$\ell_1(x, \dot{x}) = Z(x)^\top \otimes A_c - \left(\frac{\partial Z}{\partial x} \dot{x} \right)^\top \otimes I_n, \quad (3.53)$$

$$\ell_2(x) = Y(x)^\top \otimes B_c, \quad (3.54)$$

$$\ell_3(x, u) = (W(x)u)^\top \otimes B_c. \quad (3.55)$$

Folosind notațiile (3.53)–(3.55), relația algebrică asociată punctului $(x, u, \dot{x})$ devine:

$$F(x, u, \dot{x})v = 0, \quad (3.56)$$

unde:

$$F(x, u, \dot{x}) = [\ell_1(x, \dot{x}) \quad \ell_2(x) \quad \ell_3(x, u)]. \quad (3.57)$$

În lucrarea de bază, forma compactă (3.56) este introdusă pentru a transforma problema de liniarizare într-o problemă de determinare a unui vector nenul v , care satisface relația algebrică asociată datelor [4].

Pentru a utiliza relația (3.56) în context data-driven, se consideră un set finit de date colectate:

$$\mathcal{D} = \{(x_i, u_i, \dot{x}_i)\}_{i=0}^{L-1}, \quad (3.58)$$

unde x_i este starea sistemului la eșantionul i , u_i este intrarea aplicată, $\dot{x}_i$ este derivata stării în acel punct, iar L reprezintă numărul total de eșantioane. În cazul ideal, în care datele sunt curate, fără zgomot, aceste valori sunt considerate exacte sau pot fi estimate suficient de precis din datele măsurate.

Dacă derivata $\dot{x}_i$ nu este disponibilă direct, aceasta poate fi aproximată numeric. De exemplu, pentru o traiectorie discretă cu pas de eșantionare Δt , se poate utiliza formula diferențelor finite centrale:

$$\dot{x}(t_i) = \frac{x(t_{i+1}) - x(t_{i-1}))}{2\Delta t}, \quad i = 1, \dots, L-2. \quad (3.59)$$

În acest caz, relațiile de identificare se scriu pentru eșantioanele pentru care derivata este disponibilă sau poate fi estimată. În prezența zgomotului, estimarea (3.59) devine sensibilă, deoarece derivarea numerică amplifică erorile de măsurare. Din acest motiv, în subcapitolul următor se introduc filtrarea și o formă integrală a relației de identificare.

Pentru fiecare punct $(x_i, u_i, \dot{x}_i)$ din setul de date (3.58), se poate construi matricea $F(x_i, u_i, \dot{x}_i)$. Prin stivuirea tuturor acestor relații, se obține matricea dependentă de date:

$$F(\mathcal{D}) = \begin{bmatrix} F(x_0, u_0, \dot{x}_0) \\ F(x_1, u_1, \dot{x}_1) \\ \vdots \\ F(x_{L-1}, u_{L-1}, \dot{x}_{L-1}) \end{bmatrix}. \quad (3.60)$$

Dacă derivatele sunt estimate prin formula (3.59), stivuirea din (3.60) se realizează doar pentru eșantioanele interioare pentru care $\dot{x}_i$ este disponibilă. Astfel, problema de identi-

ficare devine:

$$F(\mathcal{D})v = 0. \quad (3.61)$$

Folosind relația (3.61), toate datele disponibile sunt utilizate simultan pentru determinarea coeficienților necunoscuți. Atunci când vectorul v aparține nucleului matricei $F(\mathcal{D})$, funcțiile reconstruite din matricile T , N și M satisfac relația de liniarizare în punctele din setul de date folosit.

Un aspect important menționat în lucrarea [4] este că o soluție din nucleul lui $F(\mathcal{D})$ nu este relevantă doar pe eșantioanele măsurate, ci poate fi valabilă pe întreaga regiune de interes dacă se respectă condiția de bogăție a datelor. Această condiție este exprimată printr-o constrângere de rang asupra funcțiilor de bază evaluate în punctele de date. Dacă funcțiile independente care intervin în relația de identificare sunt grupate în vectorul:

$$\phi(x, u) = \begin{bmatrix} \phi_1(x, u) \\ \phi_2(x, u) \\ \vdots \\ \phi_{n_b}(x, u) \end{bmatrix}, \quad (3.62)$$

atunci condiția de bogăție a datelor se poate scrie:

$$\text{rank} \begin{bmatrix} \phi(x_0, u_0)^\top \\ \phi(x_1, u_1)^\top \\ \vdots \\ \phi(x_{L-1}, u_{L-1})^\top \end{bmatrix} = n_b. \quad (3.63)$$

Condiția (3.63) impune ca datele să fie suficient de variate pentru a excita toate funcțiile candidate care apar în relația de identificare. În particular, este necesar ca numărul de eșantioane să fie suficient de mare, iar traiectoriile colectate să acopere adecvat regiunea de interes. Dacă eșantioanele sunt grupate într-o regiune prea restrânsă sau dacă semnalul de intrare nu introduce variații suficiente, matricea construită din date nu conține informații suficiente pentru a distinge coeficienții funcțiilor necunoscute.

Așadar, problema liniarizării se reduce la găsirea unui vector nenul v din nucleul matricei $F(\mathcal{D})$. Odată determinat acest vector, el este reorganizat în matricile T , N și M . Funcțiile identificate și folosite ulterior în legea de control sunt:

$$\hat{\tau}(x) = \hat{T} Z(x), \quad \hat{\delta}(x) = \hat{N} Y(x), \quad \hat{\gamma}(x) = \hat{M} W(x). \quad (3.64)$$

Cu toate acestea, existența unei soluții algebrice pentru (3.61) nu garantează automat că soluția este utilizabilă în control. Sunt necesare verificări suplimentare: transformarea $\hat{\tau}(x)$ trebuie să fie un difeomorfism local valid, iar $\hat{\gamma}(x)$ trebuie să fie inversabilă în zona de interes. Observația aceasta este importantă mai ales în cazul sistemelor MIMO, unde pot exista vectori în nucleul matricei $F(\mathcal{D})$ care satisfac relația algebrică, dar care nu

conduc la o transformare de coordonate validă sau la o matrice de decuplare nesingulară.

În acest subcapitol a fost prezentată partea teoretică în ipoteza în care datele sunt considerate exacte, fără zgomot de măsurare, iar relația (3.61) constituie forma algebrică centrală a metodei data-driven. În aplicațiile reale, datele de stare pot fi afectate de zgomot, iar estimarea derivatelor poate deveni dificilă. Din acest motiv, subcapitolul următor extinde formularea de mai sus la cazul în care stările sunt zgomotoase.

3.1.4 Extinderea problemei pentru cazul cu date zgomotoase

În subcapitolul precedent, relația de identificare a fost construită pornind de la cazul ideal, în care datele disponibile sunt considerate exacte. În această situație, stările, intrările și derivatele stărilor nu sunt afectate de erori de măsurare, iar matricea de date poate fi construită direct pe baza relației derivative. Această formulare este utilă în cazul fără zgomot, însă în aplicațiile practice măsurătorile stărilor sunt afectate de perturbații, iar calculul derivatelor prin diferențe finite poate amplifica semnificativ erorile. Din acest motiv, este necesară o formulare care să reducă dependența de derivarea explicită a semnalelor zgomotoase.

În continuare, intrarea $u(t)$ este considerată cunoscută și lipsită de zgomot, deoarece reprezintă semnalul generat și aplicat sistemului, putând fi salvat în timpul experimentului. În schimb, stările măsurate sunt afectate de zgomot:

$$x_m(t) = x(t) + e_x(t), \quad (3.65)$$

unde $x_m(t)$ este starea măsurată, $x(t)$ este starea reală, iar $e_x(t)$ reprezintă zgomotul de măsurare.

Dacă problema este tratată la fel ca în cazul datelor curate, dificultatea principală apare la estimarea derivatei stărilor. Derivând relația (3.65), rezultă:

$$\dot{x}_m(t) = \dot{x}(t) + \dot{e}_x(t). \quad (3.66)$$

Relația (3.66) arată că eroarea nu afectează doar starea măsurată, ci și derivata acesteia. Deoarece operația de derivare accentuează variațiile rapide ale semnalului, estimarea derivatei prin diferențe finite devine sensibilă la zgomot. De exemplu, folosind formula diferențelor finite centrale, derivata stării măsurate în momentul t_i este aproximată prin:

$$\dot{x}_m(t_i) = \frac{x_m(t_{i+1}) - x_m(t_{i-1}))}{2\Delta t}. \quad (3.67)$$

Înlocuind relația (3.65) în (3.67), se obține:

$$\dot{x}_m(t_i) = \frac{x(t_{i+1}) - x(t_{i-1}))}{2\Delta t} + \frac{e_x(t_{i+1}) - e_x(t_{i-1}))}{2\Delta t}. \quad (3.68)$$

Primul termen din (3.68) aproximează derivata stării reale, iar al doilea termen reprezintă

contribuția zgomotului. Această relație explică sensibilitatea formei derivate: diferența dintre două valori afectate de zgomot este împărțită la pasul de eșantionare Δt , astfel încât chiar și un zgomot relativ mic pe stare poate produce o eroare mare în derivată. Aceeași dificultate apare frecvent în identificarea sistemelor dinamice continue, unde stările pot fi măsurate, dar derivatele trebuie reconstruite numeric din date [12].

Pentru a reduce efectul zgomotului, o primă etapă constă în filtrarea locală a stărilor. În loc să fie utilizate direct valorile măsurate $x_m(t)$, se construiește un semnal filtrat, mai neted, notat cu $x_f(t)$. O posibilitate este ajustarea locală a unui polinom pe o fereastră de timp. Mai exact, în jurul momentului t_i , fiecare componentă a stării măsurate poate fi aproximată printr-un polinom de grad q :

$$x_m(t) \approx a_0 + a_1(t - t_i) + a_2(t - t_i)^2 + \dots + a_q(t - t_i)^q. \quad (3.69)$$

Coefficienții polinomului din (3.69) sunt determinați prin ajustare pe punctele dintr-o fereastră locală. Valoarea filtrată a stării în punctul central și derivata locală estimată sunt:

$$x_f(t_i) = a_0, \quad \dot{x}_f(t_i) = a_1. \quad (3.70)$$

Prin această procedură este estimată tendința locală a semnalului pe o fereastră de timp, în loc ca derivata să fie calculată doar din două puncte consecutive. Astfel, fluctuațiile rapide produse de zgomot sunt reduse. Totuși, chiar și după filtrare, forma derivativă rămâne sensibilă, deoarece matricea de date $F(\mathcal{D})$ depinde în continuare de o estimare a derivatei. Această observație justifică introducerea unei forme integrale a relației de identificare.

Punctul de pornire este relația de liniarizare în coordonatele transformate:

$$\dot{\tau}(x(t)) = A_c \tau(x(t)) + B_c(\delta(x(t)) + \gamma(x(t))u(t)). \quad (3.71)$$

Integrând relația (3.71) pe intervalul $[t_a, t_b]$, rezultă:

$$\tau(x(t_b)) - \tau(x(t_a)) = \int_{t_a}^{t_b} [A_c \tau(x(t)) + B_c \delta(x(t)) + B_c \gamma(x(t))u(t)] dt. \quad (3.72)$$

Forma integrală (3.72) este avantajoasă deoarece derivata stării nu mai apare explicit, iar în loc să fie estimată $\dot{x}(t)$ în fiecare punct, se folosesc valorile stării pe un interval de timp și integralele funcțiilor candidate evaluate pe traiectorie. În acest fel, formularea păstrează structura relației data-driven din subcapitolul anterior, dar reduce sensibilitatea față de erorile produse de derivarea numerică.

Înlocuind parametrizările:

$$\tau(x) = TZ(x), \quad \delta(x) = NY(x), \quad \gamma(x) = MW(x), \quad (3.73)$$

în relația (3.72), se obține relația integrală de identificare:

$$T[Z(x(t_b)) - Z(x(t_a))] - A_c T \int_{t_a}^{t_b} Z(x(t)) dt - B_c N \int_{t_a}^{t_b} Y(x(t)) dt - B_c M \int_{t_a}^{t_b} W(x(t)) u(t) dt = 0. \quad (3.74)$$

La fel ca în forma derivativă, necunoscutele din relația (3.74) sunt coeficienții din matricile T , N și M . Diferența esențială este că termenul $T \frac{\partial Z}{\partial x} \dot{x}$, prezent în forma derivativă, nu mai apare. Acesta este înlocuit de diferența $T[Z(x(t_b)) - Z(x(t_a))]$, care depinde de valorile funcțiilor candidate la capetele intervalului.

Pentru a scrie relația într-o formă compactă, se introduc următoarele notații pe intervalul $[t_a, t_b]$:

$$\Delta Z_{ab} = Z(x(t_b)) - Z(x(t_a)), \quad (3.75)$$

$$\bar{Z}_{ab} = \int_{t_a}^{t_b} Z(x(t)) dt, \quad \bar{Y}_{ab} = \int_{t_a}^{t_b} Y(x(t)) dt, \quad \bar{W}_{ab} = \int_{t_a}^{t_b} W(x(t)) u(t) dt. \quad (3.76)$$

Notațiile cu bară din (3.76) indică faptul că mărimile respective sunt obținute prin acumulare pe un interval, nu prin evaluare într-un singur punct. Cu notațiile (3.75) și (3.76), relația (3.74) devine:

$$T \Delta Z_{ab} - A_c T \bar{Z}_{ab} - B_c N \bar{Y}_{ab} - B_c M \bar{W}_{ab} = 0. \quad (3.77)$$

Utilizând produsul Kronecker și vectorizarea, termenii din relația (3.77) pot fi rescriși astfel:

$$T \Delta Z_{ab} = (\Delta Z_{ab}^\top \otimes I_n) \text{vec}(T), \quad (3.78)$$

$$A_c T \bar{Z}_{ab} = (\bar{Z}_{ab}^\top \otimes A_c) \text{vec}(T), \quad (3.79)$$

$$B_c N \bar{Y}_{ab} = (\bar{Y}_{ab}^\top \otimes B_c) \text{vec}(N), \quad (3.80)$$

$$B_c M \bar{W}_{ab} = (\bar{W}_{ab}^\top \otimes B_c) \text{vec}(M). \quad (3.81)$$

Prin urmare, pentru intervalul $[t_a, t_b]$, relația integrală poate fi scrisă sub forma:

$$F_{\text{int}}^{ab} v = 0, \quad (3.82)$$

unde v este vectorul coeficienților necunoscuți definit anterior, iar:

$$F_{\text{int}}^{ab} = [\Delta Z_{ab}^\top \otimes I_n - \bar{Z}_{ab}^\top \otimes A_c \quad -\bar{Y}_{ab}^\top \otimes B_c \quad -\bar{W}_{ab}^\top \otimes B_c]. \quad (3.83)$$

Prin stivuirea relațiilor obținute pe mai multe intervale, se construiește matricea

integrală de date:

$$F_{\text{int}}(\mathcal{D}) = \begin{bmatrix} F_{\text{int}}^{a_1 b_1} \\ F_{\text{int}}^{a_2 b_2} \\ \vdots \\ F_{\text{int}}^{a_{N_{\text{int}}} b_{N_{\text{int}}}} \end{bmatrix}, \quad (3.84)$$

unde N_{int} reprezintă numărul de intervale folosite pentru construcția matricei. În cazul datelor zgomotoase, egalitatea exactă nu mai este realistă, deoarece mărimile care intră în (3.84) sunt calculate din date măsurate și filtrate. De aceea, problema de identificare se scrie sub forma aproximativă:

$$F_{\text{int}}(\mathcal{D})v \approx 0. \quad (3.85)$$

Relația (3.85) indică faptul că se caută un vector v care produce un reziduu cât mai mic, nu unul care anulează perfect relația integrală. Pentru a evita soluția $v = 0$, această problemă trebuie completată cu condiții de normalizare sau cu o formulare de optimizare, aspect prezentat în subcapitolul următor.

În practică, integralele din (3.76) nu sunt calculate analitic, ci sunt approximate numeric din eșantioanele disponibile. Folosind regula trapezului pe stările filtrate $x_f(t_k)$, se obțin aproximațiile:

$$\bar{Z}_{ab} \approx \sum_{k=a}^{b-1} \frac{Z(x_f(t_k)) + Z(x_f(t_{k+1}))}{2} \Delta t, \quad (3.86)$$

$$\bar{Y}_{ab} \approx \sum_{k=a}^{b-1} \frac{Y(x_f(t_k)) + Y(x_f(t_{k+1}))}{2} \Delta t, \quad (3.87)$$

$$\bar{W}_{ab} \approx \sum_{k=a}^{b-1} \frac{W(x_f(t_k))u(t_k) + W(x_f(t_{k+1}))u(t_{k+1})}{2} \Delta t. \quad (3.88)$$

În aceste relații este folosită starea filtrată $x_f(t)$, deoarece dicționarele $Z(x)$, $Y(x)$ și $W(x)$ pot conține termeni neliniari, iar evaluarea lor direct pe date zgomotoase poate amplifica erorile. Filtrarea produce o traiectorie mai netedă, iar integrarea adaugă un efect suplimentar de mediere pe intervalele de timp.

Așadar, extensia pentru date zgomotoase păstrează structura relației algebrice din metoda data-driven, dar modifică modul în care este construită matricea de date. În forma derivativă se folosește matricea $F(\mathcal{D})$, care depinde de $\dot{x}$, iar în forma integrală se folosește matricea $F_{\text{int}}(\mathcal{D})$, care depinde de diferențe ale funcțiilor candidate și de integrale pe intervale de timp:

$$F(\mathcal{D})v = 0 \quad \longrightarrow \quad F_{\text{int}}(\mathcal{D})v \approx 0. \quad (3.89)$$

Prin această abordare se obțin două avantaje concrete. În primul rând, este evitată estimarea directă a derivatelor stării, operație care, în prezența zgomotului, poate introduce

erori semnificative. În al doilea rând, integrarea produce un efect natural de mediere, reducând influența variațiilor rapide din măsurători. Obiectivul rămâne însă același ca în cazul ideal: determinarea funcțiilor $\tau(x)$, $\delta(x)$ și $\gamma(x)$, reprezentate prin dicționare de funcții candidate. Diferența constă în relația folosită pentru identificare: în locul formei derivative se utilizează forma integrală. Această formulare conduce la o problemă de optimizare în care soluția este aleasă pe baza unui reziduu minim, completat cu normalizări și regularizare numerică, aspecte prezentate în subcapitolul următor.

3.1.5 Normalizarea și regularizarea problemei de identificare

Pornind de la relațiile de identificare obținute anterior, forma derivativă (3.61) și forma integrală (3.85), problema rămâne determinarea vectorului coeficienților necunoscuți v , definit în (3.47). Acest vector conține coeficienții matricilor T , N și M , care definesc funcțiile $\tau(x)$, $\delta(x)$ și $\gamma(x)$.

Un aspect esențial al relației (3.61) este caracterul său omogen. Dacă v este o soluție a relației $F(\mathcal{D})v = 0$, atunci orice multiplu nenul al acestuia este tot o soluție:

$$F(\mathcal{D})(\alpha v) = \alpha F(\mathcal{D})v = 0, \quad \alpha \neq 0. \quad (3.90)$$

În cazul formei integrale (3.85), scalarea vectorului modifică direct reziduu:

$$F_{\text{int}}(\mathcal{D})(\alpha v) = \alpha F_{\text{int}}(\mathcal{D})v. \quad (3.91)$$

Prin urmare, problema nu are o scară fixată în mod natural. Soluția nulă trebuie eliminată, iar dintre soluțiile rămase trebuie aleasă una care are sens pentru control. În lucrarea [4], soluția căutată trebuie să fie nenulă, deoarece altfel $\tau(x)$ nu poate reprezenta o schimbare de coordonate, iar $\gamma(x)$ nu poate fi nesară.

Pentru a fixa scara soluției, sunt introduse condiții de normalizare. Prima condiție este legată de punctul de echilibru al sistemului. Dacă x_e este punctul în jurul căruia se realizează liniarizarea, atunci este natural ca acesta să fie transpus în originea coordonatelor noi:

$$\tau(x_e) = 0. \quad (3.92)$$

Folosind parametrizarea $\tau(x) = TZ(x)$, condiția (3.92) devine:

$$TZ(x_e) = 0. \quad (3.93)$$

Această condiție este liniară în coeficienții matricei T . Rolul ei este de a fixa originea transformării de coordonate: dacă sistemul este stabilizat în coordonatele τ în jurul originii, atunci în coordonatele inițiale stabilizarea corespunde punctului de echilibru x_e .

O a doua normalizare este legată de termenul $\gamma(x)$, care multiplică intrarea în dinamica transformată. În cazul SISO, acest termen este scalar. O alegere simplă este

fixarea valorii lui în punctul de echilibru:

$$\gamma(x_e) = 1. \quad (3.94)$$

După înlocuirea parametrizării $\gamma(x) = MW(x)$, relația (3.94) devine:

$$MW(x_e) = 1. \quad (3.95)$$

Această condiție fixează scara soluției. Fără o asemenea normalizare, aceeași relație algebrică ar putea fi satisfăcută de soluții scalate diferit, iar interpretarea termenilor $\delta(x)$ și $\gamma(x)$ ar deveni ambiguă.

În cazul sistemelor MIMO, $\gamma(x)$ este o matrice. O normalizare convenabilă este fixarea urmei acesteia în punctul de echilibru:

$$\text{tr}(\gamma(x_e)) = m, \quad (3.96)$$

unde m este numărul de intrări ale sistemului. Înlocuind $\gamma(x) = MW(x)$, condiția (3.96) devine:

$$\text{tr}(MW(x_e)) = m. \quad (3.97)$$

Această condiție fixează scara soluției în cazul MIMO, dar nu garantează singură faptul că $\gamma(x)$ este nesingulară pe regiunea de interes. Din acest motiv, inversabilitatea lui $\gamma(x)$ rămâne o verificare separată, realizată după identificare.

Pe lângă fixarea scării, trebuie analizată și validitatea transformării de coordonate. Funcția $\tau(x)$ nu poate fi orice combinație liniară a funcțiilor din dicționar, ci trebuie să definească o schimbare de coordonate local inversabilă în regiunea de interes. Condiția locală este legată de Jacobianul transformării:

$$J_\tau(x) = \frac{\partial \tau}{\partial x}(x). \quad (3.98)$$

Deoarece $\tau(x) = TZ(x)$, iar T este o matrice constantă, rezultă:

$$J_\tau(x) = T \frac{\partial Z}{\partial x}(x). \quad (3.99)$$

Relația (3.99) depinde liniar de coeficienții din T , iar Jacobianul dicționarului $Z(x)$ este cunoscut. Prin urmare, valoarea lui $J_\tau(x_e)$ poate fi evaluată după determinarea matricei T .

Relația algebrică nu impune explicit nesingularitatea lui $J_\tau(x_e)$, astfel, o soluție care potrivește foarte bine relația de identificare poate produce o transformare singulară sau prost condiționată. În formularea utilizată în această lucrare, această problemă este tratată prin apropierea Jacobianului de matricea identitate:

$$J_\tau(x_e) \approx I_n. \quad (3.100)$$

Această condiție exprimă faptul că, local, schimbarea de coordonate trebuie să fie bine orientată în jurul punctului de echilibru. În lucrarea [4], transformarea $\tau(x)$ este definită ca difeomorfism local, iar nesingularitatea Jacobianului într-un punct interior al domeniului reprezintă o condiție suficientă pentru validitatea locală a transformării.

Pentru includerea acestei cerințe în formularea algebrică, se folosește faptul că $J_\tau(x_e)$ depinde liniar de coeficienții din T , deci și de vectorul v . Astfel, se poate construi o matrice C_J , cu blocuri nenule doar pe componentele asociate lui $\text{vec}(T)$, astfel încât:

$$C_J v = \text{vec}(J_\tau(x_e)). \quad (3.101)$$

Apropierea față de identitate este introdusă prin termenul:

$$\|C_J v - \text{vec}(I_n)\|_2^2. \quad (3.102)$$

Termenul (3.102) penalizează abaterile Jacobianului față de identitate. În acest mod, soluția nu este aleasă doar pentru că reduce reziduul algebric, ci și pentru că produce o transformare locală mai bine condiționată.

În cazul datelor fără zgomot, soluția poate fi căutată direct în nucleul matricei $F(\mathcal{D})$. În cazul datelor zgomotoase, relația de identificare nu mai poate fi satisfăcută exact, iar formularea naturală devine o problemă de minimizare a reziduului. Pentru a trata unitar cele două situații, se introduce notația:

$$F_\star(\mathcal{D}) \in \{F(\mathcal{D}), F_{\text{int}}(\mathcal{D})\}. \quad (3.103)$$

Matricea $F_\star(\mathcal{D})$ reprezintă matricea folosită în identificare: forma derivativă în cazul ideal sau forma integrală în cazul cu date zgomotoase. Termenul principal al problemei de minimizare este:

$$\|F_\star(\mathcal{D})v\|_2^2. \quad (3.104)$$

Acest termen măsoară cât de bine este satisfăcută relația de identificare. Pentru date fără zgomot, reziduul poate fi foarte mic sau chiar nul, în timp ce pentru date zgomotoase rămâne nenul și trebuie minimizat.

Minimizarea simplă a reziduului nu este însă suficientă. Atunci când dicționarele sunt bogate sau datele sunt afectate de zgomot, pot apărea soluții cu coeficienți mari, sensibile la variații mici ale datelor. Pentru reducerea acestei sensibilități, este introdus un termen de regularizare de tip Tikhonov:

$$\lambda \|v\|_2^2, \quad (3.105)$$

unde $\lambda \geq 0$ controlează intensitatea regularizării. Pentru $\lambda > 0$, termenul (3.105) penalizează soluțiile cu normă mare, reducând sensibilitatea față de variațiile mici ale datelor și stabilizând numeric problema de minimizare. Ideea regularizării este frecvent utilizată în controlul bazat pe date. În lucrarea [10], regularizările sunt interpretate ca o legătură între formulările directe și cele indirecte ale controlului bazat pe date, deoarece pot introduce

implicit un efect apropiat de identificarea unui model.

Combinând termenul de reziduu, regularizarea coeficienților și orientarea locală a transformării, problema de identificare poate fi formulată astfel:

$$\min_v \frac{1}{N_F} \|F_\star(\mathcal{D})v\|_2^2 + \lambda \|v\|_2^2 + \rho_J \|C_J v - \text{vec}(I_n)\|_2^2 \quad (3.106)$$

sub restricția:

$$C_{\text{eq}} v = b_{\text{eq}}. \quad (3.107)$$

În relația (3.106), N_F reprezintă numărul de ecuații din matricea de identificare, fiind folosit pentru normalizarea reziduului. Astfel, valoarea termenului de potrivire nu depinde direct de numărul de ecuații stivuite.

Primul termen din (3.106),

$$\frac{1}{N_F} \|F_\star(\mathcal{D})v\|_2^2, \quad (3.108)$$

măsoară cât de bine este satisfăcută relația de identificare construită din date. În cazul datelor ideale, fără zgomot, acest termen poate fi foarte mic sau nul. În cazul datelor zgomotoase, nu se mai urmărește anularea exactă a reziduului, ci obținerea unei soluții care potrivește relația de identificare în sensul celor mai mici pătrate.

Al doilea termen, $\lambda \|v\|_2^2$, este termenul de regularizare. Dacă parametrul λ este foarte mic, soluția este determinată aproape exclusiv de potrivirea pe date, ceea ce poate conduce la coeficienți mari și sensibilitate la zgomot. Dacă λ este prea mare, coeficienții sunt forțați să fie mici, iar relația de identificare poate fi potrivită mai slab. Din acest motiv, λ reprezintă un compromis între potrivirea relației data-driven și stabilitatea numerică a soluției [24].

Al treilea termen,

$$\rho_J \|C_J v - \text{vec}(I_n)\|_2^2, \quad (3.109)$$

este asociat orientării locale a transformării de coordonate. Parametrul $\rho_J \geq 0$ controlează importanța acestei penalizări. Termenul nu garantează că $\tau(x)$ este difeomorfism pe întreaga regiune de lucru, dar ajută la alegerea unei transformări locale bine condiționate în jurul punctului de echilibru.

Restricția (3.107) include condițiile impuse exact, nu prin penalizare. În această categorie intră transpunerea punctului de echilibru în originea coordonatelor noi, prin $TZ(x_e) = 0$, și fixarea scării soluției, prin $MW(x_e) = 1$ în cazul SISO sau prin $\text{tr}(MW(x_e)) = m$ în cazul MIMO. Astfel, soluția finală nu este aleasă doar pentru că potrivește relația algebrică, ci și pentru că are o scară fixată, coeficienți controlați și o transformare locală mai bine condiționată.

În articolul de bază [4], autorii arată că, pentru sistemele cu mai multe intrări și mai multe ieșiri, pot exista mai multe combinații ale vectorilor din nucleul matricei de date care satisfac expresia algebrică, dar care nu duc la o transformare de coordonate validă sau

la o matrice $\gamma(x)$ inversabilă. Din acest motiv, după identificare trebuie verificate separat validitatea transformării $\hat{\tau}(x)$ și inversabilitatea termenului $\hat{\gamma}(x)$.

După rezolvarea problemei de identificare, vectorul v este reorganizat în matricile estimate $\hat{T}$, $\hat{N}$ și $\hat{M}$, iar funcțiile identificate devin:

$$\begin{aligned}\hat{\tau}(x) &= \hat{T}Z(x), \\ \hat{\delta}(x) &= \hat{N}Y(x), \\ \hat{\gamma}(x) &= \hat{M}W(x).\end{aligned}\tag{3.110}$$

Cu aceste funcții, legea de comandă aplicată sistemului original este:

$$u = \hat{\gamma}(x)^{-1}(K\hat{\tau}(x) - \hat{\delta}(x)).\tag{3.111}$$

Matricea K este aleasă separat, pe baza formei liniare dorite în coordonatele transformate. Dinamica urmărită este:

$$\dot{\eta} = (A_c + B_c K)\eta,\tag{3.112}$$

iar K trebuie ales astfel încât $A_c + B_c K$ să fie Hurwitz, adică toate valorile proprii ale acestei matrice să aibă partea reală strict negativă. În acest caz, sistemul liniar obținut în coordonatele η este stabil. Această stabilitate se transferă sistemului neliniar original în măsura în care $\hat{\tau}(x)$ este o transformare validă și $\hat{\gamma}(x)$ rămâne inversabilă pe domeniul de lucru.

Așadar, normalizarea și regularizarea completează relația algebrică de identificare. Relația data-driven indică ce valori ale coeficienților sunt compatibile cu datele măsurate, dar singură nu garantează obținerea unei soluții unice, bine scalate și potrivite pentru control. Condițiile de normalizare fixează originea transformării și scara soluției, termenul C_J ajută la orientarea locală a transformării în jurul punctului de echilibru, iar regularizarea reduce apariția coeficienților mari și sensibilitatea la zgomot. Prin aceste elemente, problema de identificare păstrează principiul metodei din [4], dar este formulată într-o manieră mai robustă numeric și mai potrivită pentru situațiile în care datele sunt afectate de zgomot sau erori de măsurare.

3.2 Proiectare și Implementare

3.2.1 Prezentarea generală a implementării MATLAB

Implementarea MATLAB are rolul de a transpune formularea teoretică prezentată anterior într-un flux numeric complet. Acest flux pornește de la datele disponibile ale sistemului, construiește relațiile de identificare, determină coeficienții funcțiilor necunoscute și verifică prin simulare în buclă închisă legea de control obținută. Implementarea este realizată pentru sisteme neliniare continue afine în intrare, de forma generală (3.1), cu

grad relativ complet, astfel încât aceeași structură de calcul să poată fi folosită atât pentru sisteme SISO, cât și pentru sisteme MIMO.

Înainte de implementarea data-driven, metoda clasică de liniarizare prin reacție de la stare a fost utilizată ca punct de referință, etapă care permite verificarea structurii funcțiilor care apar în legea de control, respectiv transformarea de coordonate, termenul neliniar compensat și termenul de decuplare. În cazul clasic, aceste funcții sunt calculate pe baza modelului cunoscut al sistemului, prin derivate Lie și prin folosirea explicită a funcțiilor $f(x)$, $g(x)$ și, atunci când este cazul, $h(x)$. În implementarea data-driven, aceste elemente nu mai sunt calculate analitic, ci sunt identificate numeric din date, pe baza dicționarelor de funcții candidate.

În simulările realizate, modelul exact al sistemului este folosit doar pentru generarea datelor de lucru, având rolul sistemului fizic dintr-un experiment real. Această alegere permite controlul complet al condițiilor de testare și verificarea metodei în scenarii repetabile, fără ca identificarea să folosească ulterior expresiile analitice ale modelului. După generarea traiectoriilor, identificarea nu mai folosește direct modelul matematic, ci utilizează setul de date $\mathcal{D}$, format din stări, intrări și, în funcție de varianta metodei, derivate estimate sau mărimi integrale calculate pe intervale de timp. Astfel, modelul neliniar este folosit numai pentru a produce datele inițiale, în timp ce calculul funcțiilor $\hat{\tau}(x)$, $\hat{\delta}(x)$ și $\hat{\gamma}(x)$ se realizează pe baza informației extrase din date. Intrarea $u(t)$ este considerată cunoscută, deoarece reprezintă comanda aplicată sistemului și poate fi salvată în timpul experimentului.

Implementarea tratează atât cazul ideal, fără zgomot, cât și cazul în care stările sunt afectate de zgomot de măsurare. Cazul fără zgomot este folosit pentru verificarea metodei în condiții apropiate de ipotezele teoretice, în timp ce cazul zgomotos urmărește comportamentul metodei într-o situație mai apropiată de aplicațiile practice. Pentru datele zgomotoase sunt introduse etape suplimentare de prelucrare, precum filtrarea stărilor, estimarea derivatelor, construirea formei integrale a relației de identificare și regularizarea problemei de calcul.

Din punct de vedere funcțional, codul este organizat în etape succesive: configurarea sistemului, generarea datelor, prelucrarea semnalelor, evaluarea dicționarelor, construirea matricilor de identificare, determinarea coeficienților necunoscuți, verificarea condițiilor de admisibilitate, calculul regulatorului, simularea în buclă închisă și afișarea rezultatelor. Această organizare permite aplicarea aceleiași proceduri pe sisteme de complexitate diferită, de la cazuri SISO simple până la cazuri MIMO cu transformări neliniare și termeni de decuplare dependenți de stare.

Un avantaj al acestei organizări este faptul că fiecare etapă poate fi verificată separat. De exemplu, datele generate pot fi analizate înainte de identificare, matricea de identificare poate fi verificată prin dimensiuni și condiționare numerică, iar funcțiile identificate pot fi testate înainte de aplicarea regulatorului. În acest fel, implementarea nu funcționează ca un bloc unic greu de urmărit, ci ca un lanț de pași numerici care pot fi controlați și validați individual.

Pe lângă scripturile MATLAB utilizate pentru identificare și simulare, implementarea

include și o interfață grafică pentru analiza rezultatelor. Aceasta centralizează informațiile obținute după rularea algoritmului, precum valorile reziduurilor, verificările de admisibilitate, evoluțiile stărilor, comenzile aplicate și indicatorii calculați în buclă închisă. Fluxul general al implementării este sintetizat în Figura 3.1.




Figura 3.1: Fluxul general al implementării

3.2.2 Structura funcțională a codului

Implementarea MATLAB este organizată pe etape funcționale, corespunzătoare pașilor principali ai metodei. Această organizare reprezintă o împărțire logică a codului, astfel încât fiecare parte să aibă un rol clar în fluxul de calcul. În acest mod, aceeași structură poate fi păstrată pentru scenarii diferite, indiferent dacă sistemul analizat este de tip SISO sau MIMO.

Prima parte a implementării constă în configurarea generală. În această etapă se stabilesc dimensiunile sistemului, parametri de simulare, intervalul de timp, pasul de eșantionare, amplitudinea semnalelor de intrare și pragurile numerice utilizate la verificarea soluțiilor. Tot aici sunt fixați parametri specifici cazului cu date zgomotoase, precum

nivelul de zgomot adăugat pe stări, fereastra de filtrare, pasul utilizat în forma integrală și valorile de regularizare testate.

Următoarea etapă este obținerea setului de date. În simulările realizate, datele sunt generate prin integrarea modelului neliniar, folosind semnale de intrare alese astfel încât să excite suficient dinamica sistemului. Ulterior, perechile obținute $(x(t), u(t))$ sunt împărțite în date de identificare și date de validare, astfel se poate realiza verificarea soluției nu doar pe datele folosite la calculul coeficienților, ci și pe date care nu au fost utilizate în etapa de identificare.

Pentru cazul datelor zgomotoase, implementarea include o etapă suplimentară de prelucrare a semnalelor. Stările generate prin simulare sunt perturbate conform relației (3.65), iar apoi sunt aplicate proceduri de filtrare și estimare numerică a derivatelor, pas care este necesar deoarece relațiile de identificare sunt sensibile la zgomot, mai ales atunci când se folosește forma derivativă. În paralel, este pregătită și varianta integrală a metodei, descrisă prin relația (3.85), care reduce dependența de derivata stărilor.

După prelucrarea datelor, următoarea etapă este evaluarea dicționarelor de funcții definite în (3.41). Pentru fiecare eșantion de date se calculează valorile din $Z(x)$, $Y(x)$ și $W(x)$, acestea fiind folosite pentru construirea matricelor de identificare. În funcție de sistemul analizat, dicționarele pot conține termeni constanți, termeni polinomiali, funcții trigonometrice sau combinații între stări. Etapa aceasta realizează legătura dintre datele măsurate sau simulate și parametrizarea funcțiilor $\tau(x)$, $\delta(x)$ și $\gamma(x)$, prezentată în (3.42).

Partea centrală a codului este construirea matricelor de identificare și determinarea coeficienților necunoscuți grupați în vectorul v , definit în (3.47). Implementarea permite construirea matricei asociate formei derivate, notată cu $F(\mathcal{D})$, conform relațiilor (3.60) și (3.61), precum și a matricei asociate formei integrale, notată cu $F_{\text{int}}(\mathcal{D})$, conform relațiilor (3.84) și (3.85). Pe baza acestora, sunt determinați coeficienții matricelor T , N și M , ale căror dimensiuni au fost stabilite în (3.43). Pentru date neperturbate se folosește identificarea prin spațiul nul, iar pentru date zgomotoase sunt utilizate variante regularizate.

După etapa de identificare, urmează verificarea soluției obținute înainte ca aceasta să fie folosită în legea de control. Sunt calculate și analizate reziduurile pe datele de identificare și validare, inversabilitatea locală a transformării de coordonate și comportamentul termenului de decuplare. Aceste verificări sunt necesare deoarece o soluție cu reziduu mic nu este automat potrivită pentru control.

Ultima parte a implementării este dedicată simulării în buclă închisă și afișării rezultatelor. Pe baza funcțiilor identificate, reconstruite conform relației (3.110), se construiește legea de control neliniară (3.111), iar sistemul este simulat pentru a verifica stabilizarea. Rezultatele sunt afișate numeric în consola MATLAB și grafic, prin figuri, tabele și interfața de analiză. Astfel, codul permite urmărirea tuturor pașilor, de la datele inițiale până la validarea finală a comportamentului sistemului controlat.

Sucesiunea principalelor etape ale implementării este sintetizată în algoritmul 1. Acesta prezintă fluxul logic al programului, de la datele disponibile $(x(t), u(t))$, până la obținerea funcțiilor identificate și validarea sistemului în buclă închisă.

Algoritmul 1 Algoritmul general al implementării

Intrări: setul de date de lucru $\mathcal{D}$, format din stările $x(t)$ și intrările $u(t)$; dicționarele de funcții $Z(x)$, $Y(x)$ și $W(x)$.

Ieșiri: funcțiile identificate $\hat{\tau}(x)$, $\hat{\delta}(x)$, $\hat{\gamma}(x)$; legea de control neliniară construită pe baza acestora; rezultatele verificării în buclă închisă.

Pași:

1. Se configurează cazul numeric analizat: dimensiunea sistemului, numărul de intrări, timpul de simulare, pasul de eșantionare și parametri utilizați în identificare.
2. Se obțin datele de lucru $x(t)$ și $u(t)$, apoi acestea sunt împărțite în set de identificare și set de validare.
3. Se stabilește regimul de lucru. Pentru cazul ideal se folosesc datele curate, iar pentru cazul cu zgomot stările măsurate sunt definite conform relației (3.65).
4. Datele sunt prelucrate în funcție de varianta implementată: estimare numerică a derivatelor conform relației (3.59), filtrare a stărilor pentru cazul zgomotos sau pregătirea formei integrale.
5. Se evaluează dicționarele $Z(x)$, $Y(x)$ și $W(x)$, definite în (3.41), pe datele disponibile, obținând valorile numerice necesare construirii matricelor de identificare.
6. Se construiește matricea de identificare corespunzătoare variantei alese:
 - pentru forma derivativă, se construiește matricea $F(\mathcal{D})$, conform relației (3.60);
 - pentru forma integrală, se construiește matricea $F_{\text{int}}(\mathcal{D})$, conform relației (3.84).
7. Se determină vectorul coeficienților necunoscuți v , definit în (3.47):
 - pentru date neperturbate, prin determinarea unui vector din spațiul nul al matricei de identificare construite anterior;
 - pentru date zgomotoase, prin rezolvarea problemei regularizate (3.106), împreună cu restricțiile (3.107).
8. Vectorul coeficienților este despachetat în matricile $\hat{T}$, $\hat{N}$ și $\hat{M}$, iar funcțiile $\hat{\tau}(x)$, $\hat{\delta}(x)$ și $\hat{\gamma}(x)$ sunt reconstruite conform relației (3.110).
9. Se calculează reziduurile relației de identificare pe datele de identificare și pe datele de validare, folosind matricea $F_{\star}(\mathcal{D})$ definită în (3.103).
10. Se verifică admisibilitatea transformării de coordonate, folosind criteriul numeric din relația (3.113).
11. Se verifică termenul de decuplare:
 - pentru sistemele SISO, conform relației (3.115);
 - pentru sistemele MIMO, conform relației (3.116).
12. Dacă soluția este acceptată, se construiește legea de control folosind funcțiile identificate și regulatorul stabilit pentru forma liniarizată, conform relației (3.111).
13. Se simulează sistemul neliniar în buclă închisă, aplicând legea de control (3.111) asupra modelului neliniar utilizat în simulare.
14. Se calculează indicatorii utilizați ulterior la analiză: norma finală a stării, valoarea maximă a comenzii și valoarea RMS a comenzii.
15. Rezultatele sunt afișate în interfața aplicației.

3.2.3 Sisteme utilizate în implementare

Pentru verificarea implementării au fost utilizate mai multe sisteme neliniare de test, alese astfel încât dificultatea problemei să crească treptat. Toate sistemele considerate sunt sisteme continue afine în intrare, de forma generală (3.1), și sunt tratate în ipoteza de grad relativ complet. Această alegere permite aplicarea aceleiași structuri teoretice, bazate pe funcțiile $\tau(x)$, $\delta(x)$ și $\gamma(x)$, introduse în parametrizarea (3.42).

Scopul folosirii mai multor sisteme este verificarea implementării în situații cu dificultăți diferite. În cazul SISO, termenul de decuplare $\gamma(x)$ este scalar, iar verificarea admisibilității este mai simplă. În cazul MIMO, termenul de decuplare devine matriceal, iar verificarea trebuie realizată prin analiza nesingularității matricei $\hat{\gamma}(x)$, conform criteriului (3.116). Sistemele utilizate în implementare sunt sintetizate în Tabelul 3.1.

Tabelul 3.1: Sisteme neliniare utilizate pentru testarea implementării

Notatie	Tip	Structură urmărită	Rol în implementare
S1	SISO	Sistem de ordin doi, cu neliniaritate polinomială cubică și termen de decuplare scalar constant.	Verificarea fluxului de bază: generarea datelor, construirea dicționarelor, identificarea coeficienților, reconstruirea funcțiilor și simularea în buclă închisă.
S2	SISO	Sistem de ordin doi, cu neliniarități polinomiale și trigonometrice și cu termen de decuplare dependent de stare.	Testarea alegerii dicționarelor și a comportamentului metodei în prezența zgomotului de măsurare.
M1	MIMO	Sistem cu două intrări și două ieșiri, structură mai simplă și termen de decuplare matriceal.	Verificarea trecerii de la cazul scalar la cazul matriceal pentru $\gamma(x)$, precum și verificarea dimensiunilor matricelor de identificare.
M2	MIMO	Sistem cu două intrări și două ieșiri, cu neliniarități mai bogate, cuplaje între stări și decuplare dependentă de stare.	Testarea implementării într-o configurație mai complexă, apropiată de cazul final urmărit în lucrare.

Sistemul S1 reprezintă cazul de verificare inițială. Acesta are rolul de a testa implementarea într-o situație simplă, în care structura funcțiilor urmărite poate fi înțeleasă ușor, iar rezultatele obținute pot fi comparate cu forma exactă a sistemului. Pentru acest caz, termenul de decuplare este scalar, iar verificarea funcției $\hat{\gamma}(x)$ se face conform criteriului SISO din relația (3.115). Sistemul este util pentru verificarea etapelor principale ale

algoritmului fără introducerea unor dificultăți numerice mari.

Sistemul S2 păstrează structura SISO, dar introduce neliniarități mai variate și un termen de decuplare dependent de stare. Prin această alegere, implementarea nu este testată doar pe un caz polinomial simplu, ci și pe un caz în care dicționarele $Z(x)$, $Y(x)$ și $W(x)$, definite în (3.41), trebuie să conțină funcții candidate mai bogate. Acest sistem este folosit pentru a observa influența zgomotului de măsurare, importanța filtrării și diferența dintre forma derivativă și forma integrală a relației de identificare.

Sistemele M1 și M2 sunt utilizate pentru verificarea extensiei la cazul MIMO. În această situație, funcția $\gamma(x)$ nu mai este scalară, ci matriceală, iar legea de control presupune inversarea unei matrice de decuplare. Din acest motiv, pe lângă verificarea transformării de coordonate prin criteriul (3.113), trebuie verificată și nesingularitatea matricei $\hat{\gamma}(x)$, conform relației (3.116). Sistemul M1 are rolul de a testa această trecere într-un cadru mai simplu, iar sistemul M2 este folosit pentru testarea implementării într-o configurație mai dificilă, cu neliniarități mai bogate și cuplaje între stări.

Alegerea acestor sisteme urmărește o creștere graduală a dificultății. Sistemele SISO permit verificarea relației dintre date, dicționare și funcțiile identificate, într-un cadru în care termenul de decuplare este scalar. Sistemele MIMO extind verificarea la cazul matriceal, unde cresc dimensiunile matricelor de identificare, numărul coeficienților necunoscuți și complexitatea condițiilor de admisibilitate. Prin această organizare, același flux de calcul poate fi urmărit de la un caz simplu, ușor de controlat numeric, până la o configurație mai apropiată de problema completă tratată în lucrare.

În toate cazurile, modelele exacte sunt utilizate numai pentru generarea traiectoriilor și pentru simularea sistemului în buclă închisă. Etapa de identificare folosește setul de date $\mathcal{D}$, dicționarele de funcții candidate și matricele de identificare $F(\mathcal{D})$ sau $F_{\text{int}}(\mathcal{D})$, fără a utiliza direct expresiile analitice ale funcțiilor necunoscute. Astfel, sistemele de test au rolul de a verifica dacă procedura data-driven poate reconstrui funcțiile $\hat{\tau}(x)$, $\hat{\delta}(x)$ și $\hat{\gamma}(x)$, iar ulterior dacă legea de control construită pe baza acestora conduce la un comportament stabil în buclă închisă.

3.2.4 Definirea dicționarelor și pregătirea datelor

În implementarea MATLAB, funcțiile necunoscute care apar în legea de liniarizare nu sunt introduse prin expresii analitice, ci sunt reprezentate prin dicționare de funcții candidate. Pentru fiecare sistem de test sunt definite dicționarele $Z(x)$, $Y(x)$ și $W(x)$, conform structurii teoretice din (3.41). Aceste dicționare sunt introduse în cod ca funcții separate, care primesc vectorul de stare x și returnează valorile numerice ale funcțiilor de bază alese.

Organizarea permite schimbarea sistemului analizat fără modificarea întregului algoritm. Pentru un sistem nou, se modifică în principal expresiile din dicționare și dimensiunile asociate, în timp ce pașii de identificare, verificare și simulare rămân aceiași. În cazul sistemelor SISO simple, dicționarele conțin un număr redus de termeni, precum componente ale stării, termeni polinomiali sau produse între stări. Pentru sistemele mai

complexe sunt introduse și funcții trigonometrice sau combinații suplimentare între stări, astfel încât funcțiile urmărite să poată fi reprezentate mai bine.

După definirea dicționarilor, implementarea calculează dimensiunile acestora și stabilește automat dimensiunile matricelor de coeficienți T , N și M . Acest pas este important deoarece numărul coeficienților necunoscuți depinde direct de numărul funcțiilor candidate folosite. În cazul MIMO, dimensiunile cresc față de cazul SISO, deoarece trebuie identificate mai multe componente ale transformării de coordonate, ale termenului nelinier și ale termenului de decuplare.

Datele utilizate în identificare sunt obținute prin simularea sistemului nelinier pentru mai multe condiții inițiale și pentru semnale de intrare diferite. Pentru fiecare traiectorie sunt salvate stările $x(t)$ și intrările $u(t)$. Aceste date sunt apoi împărțite în două categorii: setul de identificare, folosit pentru calculul coeficienților, și setul de validare, folosit pentru verificarea soluției pe traiectorii care nu au participat la identificare.

În implementare sunt construite mai multe versiuni ale acelorași date, în funcție de varianta de identificare analizată. Pentru cazul ideal se folosesc stările curate, obținute direct din simulare. Pentru cazul cu zgomot, stările sunt perturbate conform relației (3.65), în timp ce intrarea $u(t)$ este păstrată curată, deoarece reprezintă comanda aplicată sistemului și este cunoscută în timpul experimentului numeric.

Pentru forma bazată pe derivate, derivatele stărilor sunt estimate numeric din eșantioanele disponibile. Deoarece această operație poate amplifica zgomotul, implementarea include și o variantă în care stările sunt filtrate înainte de calculul derivatelor. Filtrarea este aplicată separat pe fiecare componentă a stării și pe fiecare traiectorie, după care derivatele sunt estimate pe semnalele netezite.

Pe lângă variantele bazate pe derivate, este pregătită și forma integrală. În această variantă, datele sunt parcurse pe ferestre scurte de timp, iar în locul derivatelor punctuale sunt folosite mărimi calculate pe intervale, fiind o organizare utilă pentru cazul cu date zgomotoase, deoarece reduce dependența directă de estimarea numerică a derivatelor.

La finalul acestei etape, programul are disponibile toate elementele necesare construirii relațiilor de identificare: valorile dicționarilor evaluate pe date, derivatele estimate pentru variantele derivate, datele filtrate pentru varianta netezită și mărimile calculate pe ferestre pentru forma integrală. Aceste variante sunt păstrate separat în implementare, astfel încât rezultatele obținute prin fiecare metodă să poată fi comparate în aceleași condiții.

3.2.5 Construirea relațiilor de identificare și calculul coeficienților

După evaluarea dicționarilor și pregătirea datelor, implementarea trece la construirea matricelor de identificare. Informațiile extrase din traiectoriile simulate sunt organizate sub forma unei probleme numerice de calcul al coeficienților. În cod, coeficienții funcțiilor $\hat{\tau}(x)$, $\hat{\delta}(x)$ și $\hat{\gamma}(x)$ sunt grupați într-un singur vector necunoscut v , definit în (3.47), organizare care permite tratarea unitară a cazurilor SISO și MIMO, diferențele apărând doar în dimensiunile blocurilor și în modul de despachetare a vectorului final.

Pentru varianta bazată pe derivate, programul parcurge eșantioanele din setul de

identificare și formează, pentru fiecare punct de date, blocurile numerice din relația de identificare. În aceste blocuri sunt introduse valorile dicționarilor evaluate în starea curentă, derivatele estimate numeric ale stărilor și intrarea aplicată $u(t)$. După parcurgerea tuturor punctelor disponibile, blocurile sunt asamblate în matricea de identificare $F(\mathcal{D})$, iar relația numerică obținută are forma (3.61).

Matricea de identificare este construită separat pentru datele de identificare și pentru datele de validare. Prima matrice este folosită la calculul coeficienților, iar a doua este păstrată pentru calculul reziduuului pe traiectorii care nu au participat la identificare. Aceeași separare este utilizată pentru toate variantele implementate, astfel încât soluțiile obținute să poată fi comparate în condiții similare.

În cazul ideal, datele nu sunt afectate de zgomot, iar vectorul v se determină din spațiul nul al matricei de identificare. În cod este folosită descompunerea în valori singulare, iar vectorul asociat celei mai mici valori singulare este ales ca soluție candidată. Pentru că relația algebrică este omogenă, soluția nulă trebuie evitată, iar scara vectorului de coeficienți trebuie fixată. În implementare sunt folosite condiții de normalizare adaptate structurii fiecărui caz, cu rolul de a elimina această ambiguitate de scară și de a păstra o formă coerentă a funcțiilor identificate. Dacă nu s-ar introduce o astfel de normalizare, vectorul obținut din spațiul nul ar putea satisface relația algebrică, dar cu o scară nepotrivită pentru construcția legii de control.

Pentru datele zgomotoase, spațiul nul al matricei de identificare nu mai este bine determinat. Zgomotul de măsurare și estimarea numerică a derivatelor modifică valorile introduse în matrice, astfel încât relația (3.61) nu mai poate fi satisfăcută exact. În implementare, cazul fără zgomot este păstrat ca reper de comparație, iar pentru datele afectate de zgomot sunt analizate trei variante de identificare: derivarea numerică directă, derivarea după filtrare și forma integrală.

Prima variantă folosește direct stările zgomotoase și derivatele estimate numeric. Derivatele sunt calculate prin diferențe finite, iar punctele de la capetele traiectoriilor sunt eliminate, deoarece diferențierea numerică nu este definită uniform pentru toate eșantioanele. Pentru fiecare punct rămas sunt evaluate dicționarele și sunt adăugate blocurile corespunzătoare în matricea de identificare. Această abordare evidențiază sensibilitatea formei derivative atunci când este aplicată direct pe date afectate de zgomot.

A doua variantă folosește stările filtrate înainte de calculul derivatelor. Filtrarea este aplicată separat pe fiecare componentă a stării și pe fiecare traiectorie, iar derivatele sunt apoi estimate pe semnalele netezite. Matricea de identificare are aceeași structură ca în cazul derivativ, însă valorile numerice folosite la formarea blocurilor provin din datele filtrate, astfel se încearcă reducerea efectului zgomotului înainte de construirea relației de identificare.

A treia variantă este forma integrală a relației de identificare. În acest caz, datele sunt parcurse pe ferestre scurte de timp, iar pentru fiecare fereastră sunt calculate mărimile numerice necesare construirii relației integrale. Aceste mărimi sunt obținute din valorile stărilor la începutul și la sfârșitul ferestrei, din valorile dicționarilor evaluate pe interval și din intrarea aplicată $u(t)$, iar apoi, prin asamblarea acestor termeni se obține matricea

$F_{\text{int}}(\mathcal{D})$, care reduce dependența directă de derivatele estimate punctual.

Pentru stabilizarea identificării pe date zgomotoase este introdusă regularizarea Tikhonov. Parametrul de regularizare λ este parcurs pe o listă de valori, iar pentru fiecare valoare se calculează o soluție candidată pentru vectorul v . După calcul, soluția este normalizată, apoi sunt reconstruite matricele T , N și M . În acest fel, programul generează mai multe soluții posibile, care pot fi comparate prin aceleași criterii de verificare.

În cod sunt păstrate separat matricea asociată cazului curat de referință și matricile asociate celor trei variante cu date zgomotoase: matricea obținută prin derivare numerică directă, matricea obținută după filtrare și matricea integrală, cu rolul de a compara variantele de identificare fără modificarea structurii generale a programului. Toate variantele folosesc aceleași dicționare și aceeași formă a vectorului de coeficienți, diferența fiind dată de modul în care sunt prelucrate datele și de forma matricei de identificare construite.

După obținerea vectorului v , acesta este împărțit în blocuri corespunzătoare matricelor T , N și M , dimensiunile acestora fiind stabilite la începutul scriptului, în funcție de numărul de stări, numărul de intrări și dimensiunile dicționarilor. Pentru cazul SISO, extragerea coeficienților este mai simplă, deoarece termenul $\gamma(x)$ este scalar, iar pentru cazul MIMO vectorul v conține coeficienții mai multor componente, deoarece $\gamma(x)$ este o matrice.

Rezultatul acestei părți a implementării este reprezentat de funcțiile parametrizate $\hat{\tau}(x)$, $\hat{\delta}(x)$ și $\hat{\gamma}(x)$, obținute pentru fiecare variantă de identificare. Acestea nu sunt acceptate automat doar pentru că au fost calculate numeric, ci sunt transmise către următoarea etapă, unde sunt verificate condițiile de admisibilitate, reziduurile pe datele de identificare și validare și comportamentul sistemului în buclă închisă.

3.2.6 Verificarea soluțiilor obținute și criterii de admisibilitate

După determinarea coeficienților, soluțiile obținute nu sunt folosite direct în legea de control, ci este introdusă o etapă de verificare numerică, prin care se stabilește dacă funcțiile identificate pot fi utilizate mai departe. Acest pas este important deoarece o soluție poate avea un reziduu redus în relația de identificare, însă poate conduce la probleme în control atunci când transformarea de coordonate este prost condiționată sau când termenul de decuplare se apropie de valori care fac inversarea nesigură pe domeniul analizat.

Prima verificare implementată este cea a reziduuului de identificare. Pentru fiecare soluție candidată, codul calculează eroarea obținută prin înlocuirea vectorului de coeficienți în relația de identificare corespunzătoare variantei analizate. Pentru forma derivativă se folosește matricea $F(\mathcal{D})$, iar pentru forma integrală se folosește matricea $F_{\text{int}}(\mathcal{D})$. În mod compact, această verificare poate fi exprimată prin reziduuul asociat matricei $F_{\star}(\mathcal{D})$, definită în (3.103). Reziduuul este calculat atât pe setul de identificare, cât și pe datele de validare, pentru a evita acceptarea unei soluții care se potrivește doar pe datele folosite direct la calculul coeficienților. O soluție cu reziduu mare nu este păstrată, deoarece indică faptul că funcțiile identificate nu satisfac suficient de bine relația de identificare pe datele disponibile.

A doua verificare se referă la transformarea de coordonate. În program, Jacobianul

transformării $\hat{\tau}(x)$ este evaluat numeric pe o regiune de testare. Pentru sistemele SISO, regiunea este parcursă pe o grilă bidimensională, iar pentru sistemele MIMO este folosită o grilă corespunzătoare celor patru stări. În fiecare punct se calculează valoarea singulară minimă a Jacobianului, iar programul reține cea mai mică valoare obținută. Dacă această valoare scade sub pragul impus, soluția nu este considerată adecvată, deoarece transformarea identificată poate pierde proprietatea de inversabilitate locală pe regiunea analizată. Condiția numerică folosită este:

$$\min_{x \in \Omega} \sigma_{\min}(J_{\hat{\tau}}(x)) > \varepsilon_{\tau}, \quad (3.113)$$

unde Ω este regiunea de testare, $J_{\hat{\tau}}(x)$ este Jacobianul transformării identificate, $\sigma_{\min}(\cdot)$ reprezintă valoarea singulară minimă, iar ε_{τ} este pragul impus.

Pe lângă verificarea pe regiunea de testare, este urmărit și comportamentul local al transformării în punctul de echilibru. În aplicațiile analizate, acest punct este originea sau punctul x_e definit în etapa de configurare. În jurul acestuia se calculează abaterea Jacobianului față de matricea identitate, în concordanță cu termenul de orientare locală introdus în problema de identificare (3.106). Această verificare nu înlocuiește condiția (3.113), ci oferă o informație suplimentară despre forma locală a transformării:

$$\|J_{\hat{\tau}}(x_e) - I_n\|_2. \quad (3.114)$$

A treia verificare este asociată termenului de decuplare. Pentru sistemele SISO, acest termen este scalar, iar verificarea urmărește ca valoarea sa să nu se apropie de zero sau de valori foarte mici pe regiunea analizată:

$$\min_{x \in \Omega} |\hat{\gamma}(x)| > \varepsilon_{\gamma}, \quad (3.115)$$

unde $\hat{\gamma}(x)$ este termenul de decuplare identificat, iar ε_{γ} este pragul impus.

Pentru sistemele MIMO, termenul de decuplare este matriceal, iar verificarea urmărește ca matricea identificată să rămână nesingulară pe regiunea analizată. În acest caz, se calculează valoarea singulară minimă a matricei $\hat{\gamma}(x)$, iar condiția numerică devine:

$$\min_{x \in \Omega} \sigma_{\min}(\hat{\gamma}(x)) > \varepsilon_{\gamma}. \quad (3.116)$$

Astfel, pentru SISO se evită împărțirea la o valoare apropiată de zero, iar pentru MIMO se evită inversarea unei matrice singulare sau slab condiționate.

Pentru soluțiile obținute din date zgomotoase, verificările sunt aplicate fiecărei soluții candidate. În cod, valorile parametrului de regularizare sunt parcurse automat pentru variantele în care se rezolvă problema de minimizare, iar pentru fiecare valoare se reconstruiesc funcțiile identificate și se calculează indicatorii de verificare.

Soluția finală nu este aleasă doar pe baza unui reziduu mic, ci trebuie să respecte și condițiile legate de transformarea de coordonate și de termenul de decuplare. În acest fel

sunt eliminate soluțiile care satisfac numeric relația de identificare, dar nu pot fi utilizate în siguranță în legea de control.

După verificările de identificare și admisibilitate, soluțiile acceptate sunt folosite pentru construirea legii de control. Regulatorul este proiectat pentru forma liniarizată a sistemului, ale cărei matrice sunt definite în etapa de configurare. Pe baza acestora se calculează câștigul de reacție K , folosind metoda LQR, iar comanda este determinată cu legea neliniară (3.111), construită din funcțiile identificate. În implementare este introdusă și o limitare a comenzii, pentru a evita valori foarte mari ale semnalului de control în cazul unor soluții slab condiționate.

Ultimul pas de verificare este simularea în buclă închisă. Modelul neliniar exact este folosit aici doar ca sistem simulat, asupra căruia se aplică legea de control construită cu funcțiile identificate. Pe parcursul simulării, codul salvează evoluția stărilor, semnalul de comandă și indicatorii utilizați la analiză, precum norma finală a stării, valoarea maximă a comenzii și valoarea RMS a comenzii.

Prin acești pași, implementarea face distincția între soluțiile calculate numeric și soluțiile care pot fi folosite efectiv în control. O soluție este păstrată doar dacă are reziduuri acceptabile, respectă verificările de admisibilitate și poate fi utilizată în simularea în buclă închisă fără probleme numerice.

3.2.7 Organizarea rezultatelor în interfața aplicației

Aplicația este implementată prin fișiere MATLAB separate, specifice sistemelor cu o intrare și o singură ieșire, respectiv sistemelor cu mai multe intrări și mai multe ieșiri. Fiecare fișier păstrează aceeași structură generală, însă conține parametri specifici sistemului analizat, precum numărul de stări, numărul de intrări, dicționarele alese și setările numerice necesare. Acești parametri sunt grupați la începutul programului, pentru a putea fi modificați ușor fără schimbarea etapelor principale ale metodei.

După rulare, programul execută succesiv etapele de generare a datelor, prelucrare, construire a matricilor de identificare, calcul al coeficienților, verificare a soluțiilor și simulare în buclă închisă, afișând în consola MATLAB rezultatele intermediare, astfel încât să poată fi urmărite informații precum dimensiunea setului de date, numărul coeficienților necunoscuți, reziduurile obținute, verificările de admisibilitate și indicatorii calculați pentru bucla închisă.

Pe lângă afișarea în consolă, implementarea generează diferite figuri pentru semnalele relevante, precum evoluții ale stărilor, comparații între datele curate, zgomotoase și filtrate, semnale de comandă și evoluții în buclă închisă. Pentru o organizare mai clară a informațiilor, a fost realizată o interfață grafică care grupează rezultatele în secțiuni și oferă un mod mai compact de prezentare și urmărire a rezultatelor obținute prin rularea programului.

Pentru exemplificare, în Figura 3.2 este prezentată prima secțiune a interfeței pentru sistemul SISO S2. Aceasta conține informațiile generale ale rulării, metodele selectate, reziduuri de validare, indicatori de admisibilitate și evoluția stărilor în buclă închisă.




Figura 3.2: Interfața aplicației pentru sistemul SISO S2

Celelalte secțiuni ale interfeței păstrează aceeași logică și detaliază separat datele, matricele de identificare, coeficienții calculați, transformarea identificată și rezultatele simulării în buclă închisă.

Astfel, prin această organizare, aplicația poate fi utilizată într-un mod clar și reproductibil, fiecare fișier parcurgând etapele necesare, de la configurarea cazului numeric până la obținerea soluțiilor identificate și afișarea informațiilor relevante în interfața grafică.

3.3 Testare și Validare

3.3.1 Metodologia de testare

După implementarea algoritmului în mediul MATLAB, etapa următoare constă în testarea și validarea soluțiilor obținute. Scopul acestui pas este de a verifica dacă funcțiile identificate permit construirea unei legi de control și dacă rezultatele rămân acceptabile atunci când datele sunt afectate de zgomot.

Experimentele au fost realizate pe sisteme de tip SISO și MIMO, prezentate în Tabelul 3.1, progresând de la cazuri simple la cazuri mai complexe, iar pentru fiecare sistem au fost analizate două scenarii. Primul scenariu corespunde cazului ideal, fără zgomot, în care metoda este verificată în condiții apropiate de formularea teoretică. Al doilea scenariu corespunde cazului cu zgomot pe stări, în care datele măsurate sunt perturbate, iar intrarea aplicată rămâne cunoscută și curată.

În ambele situații, datele sunt împărțite în set de identificare și set de validare, astfel încât soluțiile obținute să poată fi verificate și pe traiectorii care nu au participat la calculul coeficienților.

În absența zgomotului, metoda principală este bazată pe spațiul nul al matricei de identificare, în timp ce pentru cazul cu zgomot au fost comparate mai multe variante: aplicarea directă a metodei pe datele zgomotoase, forma derivativă cu filtrare și regularizare Tikhonov și forma integrală cu regularizare Tikhonov. Comparația este realizată cu scopul de a observa care variantă produce soluții admisibile și utilizabile în control, nu doar soluții cu reziduu redus.

Pentru a valida o soluție au fost utilizate mai multe criterii. Primul dintre acestea este reziduu asociat matricei $F_*(\mathcal{D})$, calculat pe datele de identificare și pe datele de validare. Al doilea criteriu este admisibilitatea transformării de coordonate, verificată prin relația (3.113), iar al treilea criteriu este admisibilitatea termenului de decuplare, verificată prin relațiile (3.115), respectiv (3.116).

În final, soluțiile acceptate numeric sunt testate prin simularea sistemului în buclă închisă. Pentru aceasta, legea de control este construită cu funcțiile identificate, iar regulatorul este stabilit pentru forma liniarizată a sistemului. În timpul simulării sunt urmăriti indicatori precum eroarea finală față de punctul de echilibru (3.117), valoarea maximă a normei comenzii (3.118) și valoarea RMS a comenzii (3.119), care permit evaluarea comportării sistemului controlat și a nivelului semnalului de comandă obținut în timpul simulării.

Astfel, validarea nu se rezumă doar la relația de identificare, ci urmărește și efectul soluției asupra comportării dinamice a sistemului.

În continuare, rezultatele obținute sunt prezentate sub formă de tabele și grafice extrase din interfața MATLAB. Tabelele sunt folosite pentru sintetizarea valorilor numerice relevante, iar graficele ilustrează efectul zgomotului asupra datelor, influența filtrării și comportarea sistemelor controlate. Analiza este realizată gradual, de la datele utilizate în experimente până la rezultatele identificării și validarea soluțiilor în buclă închisă.

3.3.2 Generarea datelor în simulare și influența zgomotului

Într-o aplicație experimentală, setul de date necesar metodei ar fi obținut prin aplicarea unei comenzi cunoscute asupra sistemului și prin înregistrarea evoluției stărilor măsurate, astfel, informațiile disponibile ar fi comanda aplicată $u(t)$ și stările măsurate $x_m(t)$. În această lucrare, deoarece validarea este realizată în simulare, acest set de date este construit prin simularea modelelor neliniare în MATLAB.

Pentru fiecare sistem au fost generate mai multe traiectorii, pornind de la condiții inițiale diferite și aplicând semnale de intrare cunoscute. Între două momente consecutive de eșantionare, comanda a fost menținută constantă, iar stările au fost obținute prin integrarea modelului neliniar.

În urma simulării au fost salvate stările curate $x(t)$, comenzile aplicate $u(t)$ și derivatele exacte $\dot{x}(t)$, calculate pe baza modelului. Aceste mărimi sunt folosite pentru

cazul de referință fără zgomot și pentru calculul erorilor de estimare, însă în cazul practic cu date zgomotoase se consideră disponibile numai intrarea aplicată și stările măsurate.

Pentru sistemele SISO, condițiile inițiale au fost generate aleator în jurul punctului de echilibru, iar semnalul de intrare a alternat între valori aleatoare și semnale sinusoidale sau cosinusoidale cu o componentă aleatoare suplimentară. Intrarea a fost limitată în jurul comenzii de echilibru, în intervalul $u_e \pm A_u$, unde A_u reprezintă amplitudinea de excitație.

Pentru sistemele MIMO, condițiile inițiale au fost generate aleator în jurul originii, iar intrarea a avut două componente, fiind folosite pe rând excitații aleatoare pe ambele canale, excitații aplicate separat pe câte un canal și semnale sinusoidale aplicate simultan pe cele două intrări.

Parametrii utilizați pentru generarea și prelucrarea datelor sunt sintetizați în Tabelul 3.2. Numărul total de puncte folosite pentru identificare și validare rezultă din produsul dintre numărul de traiectorii și numărul de pași ai fiecărei traiectorii.

Tabelul 3.2: Parametrii utilizați pentru generarea și prelucrarea datelor

Sistem	dt	Traectorii ID $\times$ pași	Traectorii VAL $\times$ pași	A_u	Fereastră filtrare	Pas integral
S1	0.05	32×175	8×150	1.20	13	5
S2	0.035	34×180	9×155	0.85	11	6
M1	0.05	30×181	8×151	1.20	15	7
M2	0.04	32×165	8×145	0.75	9	5

Pentru fiecare sistem au fost generate date atât în regim ideal, fără zgomot, cât și în regim zgomotos. Datele fără zgomot sunt folosite ca referință pentru verificarea metodei în condiții apropiate de formularea teoretică. În scenariul cu date zgomotoase, zgomotul a fost introdus numai pe stări, obținându-se semnalele măsurate $x_m(t)$, iar intrarea $u(t)$ a fost considerată cunoscută și neperturbată. Această alegere reflectă ipoteza că semnalul de comandă este impus și salvat, fără a fi afectat de zgomot, iar incertitudinea apare la nivelul măsurării stărilor.

Nivelul de zgomot s-a menținut constant la $\text{SNR}_x = 25$ dB, pentru ca rezultatele celor patru sisteme să poată fi comparate în aceleași condiții de măsurare. Stările zgomotoase au fost apoi filtrate prin aproximare polinomială locală de ordin 3, folosind fereastra indicată în Tabelul 3.2. Derivatele au fost estimate numeric atât din stările zgomotoase, cât și din stările filtrate, iar erorile rezultate au fost calculate prin comparație cu semnalele curate generate de model.

În Tabelul 3.3 sunt prezentate datele folosite și indicatorii numerici obținuți în urma prelucrării semnalelor. Coloanele *Puncte ID* și *Puncte VAL* indică numărul de puncte folosite pentru identificare, respectiv pentru validare, mărimea σ_x este abaterea standard a zgomotului introdus pe stări, indicatorii $RMSE_{x_m}$ și $RMSE_{x_f}$ descriu eroarea stării măsurate, respectiv eroarea stării filtrate, iar $RMSE_{\dot{x}_{brut}}$ și $RMSE_{\dot{x}_f}$ descriu eroarea derivatelor estimate înainte și după filtrare.

Tabelul 3.3: Datele folosite și nivelul de zgomot pentru cele patru sisteme

Sistem	Puncte ID	Puncte VAL	σ_x	RMSE x_m	RMSE x_f	RMSE $\dot{x}_{brut}$	RMSE $\dot{x}_f$
S1	5600	1200	$2.1414 \cdot 10^{-2}$	$2.1471 \cdot 10^{-2}$	$1.3770 \cdot 10^{-2}$	$3.7072 \cdot 10^{-1}$	$2.7281 \cdot 10^{-1}$
S2	6120	1395	$1.5802 \cdot 10^{-2}$	$1.5847 \cdot 10^{-2}$	$9.8343 \cdot 10^{-3}$	$3.8295 \cdot 10^{-1}$	$2.7676 \cdot 10^{-1}$
M1	5430	1208	$3.9252 \cdot 10^{-2}$	$3.9255 \cdot 10^{-2}$	$2.1290 \cdot 10^{-2}$	$6.2173 \cdot 10^{-1}$	$3.6122 \cdot 10^{-1}$
M2	5280	1160	$4.3141 \cdot 10^{-2}$	$4.3193 \cdot 10^{-2}$	$2.2804 \cdot 10^{-2}$	$7.9055 \cdot 10^{-1}$	$4.2578 \cdot 10^{-1}$

Din valorile prezentate în tabel se poate observa că filtrarea reduce eroarea stărilor pentru toate sistemele analizate, contribuind la obținerea unor semnale de stare mai netede înainte de construirea relațiilor de identificare. Totuși, erorile asociate derivatelor sunt semnificativ mai mari decât erorile asociate stărilor, ceea ce arată că derivarea numerică amplifică efectul zgomotului. Așadar, pasul de filtrare a datelor reduce doar parțial acest efect, fără a elimina complet sensibilitatea estimării derivatelor.

Pentru exemplificarea efectului zgomotului asupra semnalelor, în Figura 3.3 este prezentat un caz reprezentativ. În primul grafic se compară starea curată, starea măsurată cu zgomot și starea filtrată, iar în al doilea grafic se compară derivata exactă cu derivatele estimate înainte și după filtrare.




Figura 3.3: Influența zgomotului și a filtrării asupra unei stări și a derivatei estimate

Din aceste grafice se observă că filtrarea netezește semnalul de stare, însă efectul zgomotului rămâne mai pronunțat în cazul derivatei estimate numeric. Semnalul filtrat urmărește bine evoluția stării curate, ceea ce arată că prelucrarea datelor reduce

variațiile rapide introduse de zgomot. În schimb, derivata brută prezintă oscilații vizibile, iar derivata filtrată rămâne doar o aproximare a derivatei exacte.

3.3.3 Validarea metodei în cazul fără zgomot

În această parte a fost analizat cazul fără zgomot, utilizat ca referință pentru verificarea implementării metodei. În absența zgomotului, relația de identificare este construită folosind datele curate, iar soluția este obținută prin determinarea unei soluții admisibile din spațiul nul al matricei de identificare.

Pentru fiecare sistem au fost urmărite reziduul pe datele de identificare, reziduul pe datele de validare și condițiile de admisibilitate. Indicatorul $\min \sigma(J_{\hat{\tau}})$ este folosit pentru verificarea transformării de coordonate identificate, conform relației (3.113). Ultima coloană verifică termenul de decuplare: pentru sistemele SISO este urmărită valoarea $\min |\hat{\gamma}(x)|$, conform relației (3.115), iar pentru sistemele MIMO este urmărită valoarea $\min \sigma_{\min}(\hat{\gamma}(x))$, conform relației (3.116). Rezultatele obținute sunt prezentate în Tabelul 3.4.

Tabelul 3.4: Validarea metodei în cazul fără zgomot

Sistem	Reziduu ID	Reziduu VAL	$\min \sigma(J_{\hat{\tau}})$	Indicator $\hat{\gamma}$
S1	4.9799×10^{-12}	4.4023×10^{-12}	1.9867×10^{-1}	3.9867×10^{-1}
S2	2.2896×10^{-12}	2.2536×10^{-12}	6.2237×10^{-1}	9.2226×10^{-1}
M1	1.2447×10^{-11}	8.3705×10^{-12}	9.5329×10^{-1}	9.7950×10^{-1}
M2	1.2698×10^{-11}	4.9277×10^{-12}	6.5877×10^{-1}	9.0724×10^{-1}

Valorile din tabel arată că, în cazul fără zgomot, reziduurile obținute sunt foarte mici pentru toate sistemele analizate. Acestea sunt de ordinul 10^{-12} – 10^{-11} , ceea ce indică faptul că relația de identificare este satisfăcută cu o eroare redusă, atât pe datele de identificare, cât și pe datele de validare.

Totodată, indicatorii de admisibilitate rămân favorabili și confirmă faptul că soluțiile identificate pot fi utilizate mai departe. Valorile asociate transformării $\hat{\tau}$ rămân pozitive și peste pragul impus, iar indicatorul asociat lui $\hat{\gamma}$ este suficient de îndepărtat de zero. Acest lucru arată că transformarea de coordonate rămâne nesingulară în regiunea analizată, iar termenul de decuplare permite construirea legii de control fără probleme de singularitate.

Prin urmare, rezultatele obținute validează implementarea în cazul ideal, în care datele nu sunt afectate de zgomot, confirmă că implementarea funcționează corect în condiții ideale și oferă o referință importantă pentru cazul zgomotos, unde se așteaptă reziduuri mai mari și o sensibilitate numerică mai ridicată.

3.3.4 Validarea metodei în cazul cu date zgomotoase

După validarea cazului fără zgomot, metoda a fost analizată pentru situația în care stările sunt afectate de zgomot de măsurare. Pentru fiecare sistem au fost urmărite aceleași

mărimi ca în cazul ideal: reziduul pe datele de identificare, reziduul pe datele de validare, admisibilitatea transformării de coordonate identificate și admisibilitatea termenului de decuplare.

Pentru acest caz, soluțiile acceptate au fost obținute folosind forma integrală a relației de identificare împreună cu regularizarea Tikhonov. Această variantă a fost selectată deoarece a furnizat soluții cu reziduuri de validare acceptabile și cu indicatori de admisibilitate corespunzători. Parametrul λ controlează influența termenului de regularizare asupra soluției: valori mai mici permit o potrivire mai apropiată a relației de identificare, iar valori mai mari limitează variația coeficienților identificați și ajută la stabilizarea numerică a soluției.

Rezultatele obținute sunt prezentate în Tabelul 3.5, unde coloana λ reprezintă coeficientul de regularizare utilizat pentru soluția finală a fiecărui sistem.

Tabelul 3.5: Validarea metodei în cazul datelor zgomotoase

Sistem	λ	Reziduu ID	Reziduu VAL	$\min \sigma(J_{\hat{\tau}})$	Indicator $\hat{\gamma}$
S1	4.5316×10^{-8}	8.2564×10^{-3}	7.9588×10^{-3}	8.3233×10^{-1}	7.4980×10^{-1}
S2	4.4893×10^{-5}	1.5902×10^{-2}	1.5365×10^{-2}	7.8143×10^{-2}	9.5627×10^{-1}
M1	1.0000×10^{-8}	9.5622×10^{-3}	9.3847×10^{-3}	9.8158×10^{-1}	9.7152×10^{-1}
M2	6.8840×10^{-4}	1.5115×10^{-2}	1.3910×10^{-2}	2.0576×10^{-1}	3.4522×10^{-1}

În această situație, deoarece datele de stare sunt perturbate, relația de identificare nu mai poate fi satisfăcută cu reziduuri foarte mici, ca în cazul ideal, ci reziduurile cresc și ajung la ordinul 10^{-3} – 10^{-2} , ceea ce este de așteptat în prezența zgomotului de măsurare. Totuși, valorile obținute pe datele de validare sunt apropiate de cele obținute pe datele de identificare, ceea ce sugerează că soluțiile nu sunt adaptate doar la setul folosit pentru calculul coeficienților.

Se observă că valorile parametrului λ sunt diferite de la un sistem la altul, acestea fiind alese prin evaluarea mai multor valori candidate. Pentru sistemele mai simple sunt suficiente valori mai mici ale regularizării, în timp ce pentru sistemele mai complexe este necesară o regularizare mai pronunțată. Acest lucru este vizibil în special pentru S2 și M2, unde neliniaritățile și dependența de stare a termenului de decuplare conduc la valori mai mari ale parametrului λ .

Un alt aspect important este că, pentru toate cele patru situații, valorile indicatorului $\min \sigma(J_{\hat{\tau}})$ și ale indicatorului asociat lui $\hat{\gamma}$ se mențin peste limitele impuse, ceea ce asigură o transformare de coordonate validă și un termen de decuplare care poate fi utilizat în calculul comenzii fără apariția unor probleme de singularitate.

Prin urmare, rezultatele obținute confirmă faptul că metoda poate produce soluții admisibile și în cazul datelor zgomotoase, atunci când identificarea este realizată prin forma integrală și regularizare Tikhonov. Soluțiile prezentate în Tabelul 3.5 sunt cele care vor fi folosite în etapa de validare în buclă închisă.

3.3.5 Compararea metodelor de identificare

Pentru a justifica alegerea soluțiilor finale obținute în cazul cu date zgomotoase, au fost comparate metodele utilizate în etapa de identificare. Scopul acestei comparații este de a evidenția diferența dintre aplicarea directă a metodei pe date perturbate, utilizarea derivatelor filtrate și utilizarea formei integrale cu regularizare Tikhonov.

În Tabelul 3.6 sunt prezentate rezultatele obținute pentru cele trei variante analizate. Coloana „Criteriu relevant” indică mărimea sau condiția care a influențat decizia de acceptare sau respingere, iar pentru metodele respinse este prezentat criteriul care justifică cel mai clar motivul respingerii. Această comparație este necesară deoarece un reziduu mic nu garantează automat o soluție utilizabilă pentru control, din acest motiv, fiecare metodă fiind evaluată atât prin precizia identificării, cât și prin respectarea condițiilor de admisibilitate pentru transformarea de coordonate și termenul de decuplare.

Tabelul 3.6: Comparația metodelor de identificare în cazul datelor zgomotoase

Sistem	Metodă	Criteriu relevant	Decizie
S1	Direct pe date zgomotoase	condiții de normalizare nerespectate	Respinsă
S1	Derivativă filtrată + Tikhonov	$Rez_{VAL} = 8.2185 \times 10^{-2}$, $\min \hat{\gamma} = 8.0262 \times 10^{-3}$	Respinsă
S1	Integrală + Tikhonov	$Rez_{VAL} = 7.9588 \times 10^{-3}$, $\min \sigma(J_{\hat{\tau}}) = 8.3233 \times 10^{-1}$, $\min \hat{\gamma} = 7.4980 \times 10^{-1}$	Acceptată
S2	Direct pe date zgomotoase	condiții de normalizare nerespectate	Respinsă
S2	Derivativă filtrată + Tikhonov	$Rez_{VAL} = 9.7158 \times 10^{-3}$, $\min \sigma(J_{\hat{\tau}}) = 1.3172 \times 10^{-3}$, $\min \hat{\gamma} = 7.7131 \times 10^{-3}$	Respinsă
S2	Integrală + Tikhonov	$Rez_{VAL} = 1.5365 \times 10^{-2}$, $\min \sigma(J_{\hat{\tau}}) = 7.8143 \times 10^{-2}$, $\min \hat{\gamma} = 9.5627 \times 10^{-1}$	Acceptată
M1	Direct pe date zgomotoase	spațiu nul numeric neadecvat	Respinsă
M1	Derivativă filtrată + Tikhonov	$Rez_{VAL} = 1.2844 \times 10^{-1}$	Respinsă
M1	Integrală + Tikhonov	$Rez_{VAL} = 9.3847 \times 10^{-3}$, $\min \sigma(J_{\hat{\tau}}) = 9.8158 \times 10^{-1}$, $\min \sigma(\hat{\gamma}) = 9.7152 \times 10^{-1}$	Acceptată
M2	Direct pe date zgomotoase	spațiu nul numeric neadecvat; soluție degenerată	Respinsă
M2	Derivativă filtrată + Tikhonov	$Rez_{VAL} = 1.6804 \times 10^{-1}$	Respinsă
M2	Integrală + Tikhonov	$Rez_{VAL} = 1.3910 \times 10^{-2}$, $\min \sigma(J_{\hat{\tau}}) = 2.0576 \times 10^{-1}$, $\min \sigma(\hat{\gamma}) = 3.4522 \times 10^{-1}$	Acceptată

Un prim aspect care se observă din aceste rezultate este faptul că aplicarea directă a metodei pe date zgomotoase nu conduce la soluții utilizabile pentru niciun sistem analizat. Pentru sistemele SISO, respingerea apare din cauza nerespectării condițiilor de normalizare, iar pentru sistemele MIMO apar probleme la determinarea unei soluții numerice din spațiul nul. Acest rezultat arată că relația de identificare este sensibilă la zgomot atunci când este aplicată direct pe date perturbate.

Varianta derivativă filtrată cu regularizare Tikhonov îmbunătățește parțial situația, însă nu este suficientă pentru acceptarea soluțiilor. În cazul S1, reziduu de validare nu este principala problemă, însă termenul de decuplare are valoarea minimă $\min |\hat{\gamma}| = 8.0262 \times 10^{-3}$, ceea ce indică o problemă de admisibilitate. Similar, pentru sistemul S2, deși reziduu de validare este redus, $Rez_{VAL} = 9.7158 \times 10^{-3}$, indicatorii de admisibilitate sunt foarte mici: $\min \sigma(J_{\hat{\tau}}) = 1.3172 \times 10^{-3}$ și $\min |\hat{\gamma}| = 7.7131 \times 10^{-3}$. Pentru sistemele MIMO, limitarea principală este reziduu de validare, care ajunge la 1.2844×10^{-1} pentru M1 și la 1.6804×10^{-1} pentru M2, fiind peste pragul impus.

Forma integrală cu regularizare Tikhonov oferă cele mai bune rezultate dintre variantele testate. Pentru toate cele patru sisteme, reziduurile de validare rămân de ordinul 10^{-2} sau mai mici, iar indicatorii de admisibilitate rămân peste limitele impuse, atât pentru

transformarea de coordonate $\hat{\tau}(x)$, cât și pentru termenul de decuplare $\hat{\gamma}(x)$.

Prin comparație, se observă că filtrarea derivatelor reduce efectul zgomotului, dar nu garantează obținerea unei soluții utilizabile pentru control. Forma integrală este mai robustă, deoarece conduce simultan la reziduuri de validare acceptabile și la indicatori de admisibilitate corespunzători. Din acest motiv, metoda integrală cu regularizare Tikhonov este aleasă ca variantă finală pentru cazul datelor zgomotoase și este utilizată în etapa de validare în buclă închisă.

3.3.6 Validare în buclă închisă

După selectarea soluțiilor admisibile, ultima etapă de testare constă în validarea acestora în buclă închisă. În această etapă, funcțiile identificate $\hat{\tau}(x)$, $\hat{\delta}(x)$ și $\hat{\gamma}(x)$ sunt utilizate în legea de control, iar sistemul neliniar este simulat pentru a verifica dacă stările converg către punctul de echilibru. Această verificare este importantă deoarece o soluție care trece criteriile de identificare trebuie să fie utilizabilă și din punctul de vedere al controlului.

Regulatorul a fost stabilit pe forma liniarizată a sistemului, folosind un câștig K ales astfel încât matricea $A_c + B_c K$ să fie stabilă. În implementare, câștigul a fost calculat prin metoda LQR , iar apoi, a fost calculată legea de control (3.111). Pentru fiecare configurație au fost obținuți poli stabili ai sistemului închis, prezentați în Tabelul 3.7. Valorile acestora indică faptul că dinamica liniarizată utilizată în proiectarea controlului este stabilă.

Tabelul 3.7: Poli sistemului liniarizat utilizați la proiectarea regulatorului

Sistem	Tip sistem	Poli în buclă închisă
S1	SISO	$-2.0402 \pm 1.4705i$
S2	SISO	$-1.4195 \pm 1.1348i$
M1	MIMO	$-2.0402 \pm 1.4705i, -1.6756 \pm 1.2902i$
M2	MIMO	$-1.1111 \pm 0.9346i, -1.0418 \pm 0.8862i$

Stabilitatea acestor poli reprezintă o condiție necesară pentru proiectarea regulatorului pe sistemul liniarizat, însă nu este suficientă pentru a garanta comportarea sistemului neliniar atunci când sunt folosite funcțiile identificate. Din acest motiv, fiecare soluție acceptată este verificată suplimentar prin simulare neliniară în buclă închisă. Pentru validarea în buclă închisă au fost urmărite norma finală a stării, valoarea maximă a comenzii și valoarea RMS a comenzii. Aceste mărimi au fost calculate conform relațiilor:

$$\|x(T) - x_e\|, \quad (3.117)$$

$$u_{\max} = \max_{t \in [0, T]} \|u(t)\|, \quad (3.118)$$

$$u_{\text{RMS}} = \sqrt{\frac{1}{T} \int_0^T \|u(t)\|^2 dt}. \quad (3.119)$$

Pentru sistemele SISO, norma comenzii se reduce la valoarea absolută a comenzii scalare, iar pentru sistemele MIMO se utilizează norma vectorului de comandă. În Tabelul 3.8 sunt comparate soluțiile obținute din date ideale prin metoda bazată pe spațiul nul (SVD) și soluțiile obținute din date zgomotoase prin forma integrală cu regularizare Tikhonov.

Tabelul 3.8: Rezultatele validării în buclă închisă

Sistem	Caz analizat	$\ x(T) - x_e\ $	$u_{\max}$	u_{RMS}
S1	Date neperturbate, SVD	1.7363×10^{-9}	2.6904	2.9597×10^{-1}
S1	Date zgomotoase, integrală + Tikhonov	2.6994×10^{-4}	1.9905	2.4560×10^{-1}
S2	Date neperturbate, SVD	7.9981×10^{-13}	7.4083×10^{-1}	1.2922×10^{-1}
S2	Date zgomotoase, integrală + Tikhonov	5.9206×10^{-3}	7.8604×10^{-1}	1.2972×10^{-1}
M1	Date neperturbate, SVD	1.5604×10^{-6}	2.0184	3.0275×10^{-1}
M1	Date zgomotoase, integrală + Tikhonov	3.1308×10^{-7}	2.1264	3.0995×10^{-1}
M2	Date neperturbate, SVD	1.1576×10^{-17}	1.7599×10^{-1}	1.1225×10^{-1}
M2	Date zgomotoase, integrală + Tikhonov	9.5556×10^{-2}	1.1445×10^{-1}	7.7433×10^{-2}

Rezultatele din Tabelul 3.8 confirmă faptul că soluțiile obținute în etapa de identificare pot fi utilizate în legea de control. Pentru datele curate, metoda bazată pe spațiul nul SVD conduce la valori foarte mici ale normei finale a stării, între 10^{-17} și 10^{-9} pentru sistemele SISO și pentru sistemul M2, respectiv de ordinul 10^{-6} pentru M1. Aceste valori arată că, în absența zgomotului, relația de identificare permite obținerea unei legi de control care stabilizează corect sistemul neliniar.

În cazul datelor zgomotoase, soluțiile obținute prin forma integrală cu regularizare Tikhonov păstrează comportarea stabilă în buclă închisă. Pentru sistemele SISO, norma finală a stării rămâne redusă, având valoarea 2.6994×10^{-4} pentru S1 și 5.9206×10^{-3} pentru S2. Pentru sistemul M1, rezultatul este 3.1308×10^{-7} , valoare foarte redusă și comparabilă cu cea obținută în cazul datelor curate. Pentru sistemul M2 se obține cea mai mare abatere, $\|x(T) - x_e\| = 9.5556 \times 10^{-2}$, ceea ce este explicabil prin complexitatea mai ridicată a sistemului, prin neliniaritățile mai pronunțate și prin matricea de decuplare dependentă de stare. Aceste rezultate arată că evaluarea în buclă închisă nu trebuie făcută doar prin verificarea convergenței stărilor, ci și prin analiza efortului de comandă. O soluție poate avea o eroare finală redusă, dar poate deveni mai puțin potrivită dacă necesită valori mari ale comenzii sau dacă introduce oscilații în semnalul de control. Analiza comenzii arată că valorile $u_{\max}$ și u_{RMS} rămân în domenii numerice rezonabile. Pentru S1, comanda RMS în cazul datelor zgomotoase este 2.4560×10^{-1} , apropiată de valoarea obținută pentru date fără zgomot. Pentru S2 și M1, valorile RMS sunt de asemenea apropiate între cele două cazuri analizate, ceea ce indică faptul că regularizarea nu conduce la comenzi excesive. În cazul M2, comanda obținută pentru date zgomotoase are o amplitudine mai redusă, însă cu prețul unei erori finale mai mari a stării.

Pentru a completa analiza numerică, în Figura 3.4 este prezentată evoluția stărilor în buclă închisă pentru un caz reprezentativ SISO, mai exact pentru sistemul S2. Pe lângă răspunsurile obținute din date neperturbate și din date zgomotoase, este inclusă și referința

exactă, utilizată ca reper de comparație. Sistemul S2 a fost ales deoarece are neliniarități mai pronunțate decât S1 și permite observarea diferențelor dintre cazurile analizate.




Figura 3.4: Evoluția stărilor în buclă închisă pentru sistemul SISO S2

Din această figură se observă că ambele stări converg către punctul de echilibru. Traiectoriile obținute pentru cazul zgomotos urmăresc aceeași tendință generală ca în cazul datelor curate, chiar dacă apar mici diferențe pe durata regimului tranzitoriu. Răspunsurile obținute pentru date ideale și pentru date zgomotoase sunt apropiate de referința exactă, ceea ce arată că soluția identificată păstrează comportarea stabilizatoare a regulatorului.

În Figura 3.5 este prezentată norma erorii față de punctul de echilibru, împreună cu evoluția semnalului de comandă. Această reprezentare permite verificarea simultană a convergenței sistemului și a nivelului comenzii aplicate.




Figura 3.5: Norma erorii și evoluția comenzii în buclă închisă pentru sistemul SISO S2

Acest set de grafice confirmă faptul că norma erorii scade către valori apropiate de zero, iar comanda rămâne limitată pe durata simulării. În cazul datelor zgomotoase, răspunsul nu coincide perfect cu cel obținut din date fără zgomot, însă diferențele sunt reduse și nu apar oscilații sau creșteri necontrolate ale comenzii. De asemenea, se poate observa că rezultatul este în concordanță cu valorile din Tabelul 3.8.

Prin urmare, rezultatele numerice și grafice obținute în buclă închisă confirmă faptul că soluțiile selectate pe baza criteriilor de identificare sunt utilizabile și din punctul de vedere al controlului. În cazul datelor curate, metoda bazată pe spațiul nul SVD rămâne varianta potrivită, deoarece conduce la o identificare precisă și la stabilizarea sistemului. În cazul datelor zgomotoase, aplicarea formei integrale cu regularizare Tikhonov oferă un compromis favorabil între stabilizarea sistemului, limitarea comenzii și robustețea față de zgomot. Această etapă susține alegerea metodei integrale regularizate ca variantă finală atunci când identificarea și controlul sunt realizate pe baza unor date afectate de zgomot.

3.3.7 Sinteza rezultatelor obținute

Rezultatele obținute în această secțiune evidențiază diferența dintre identificarea în condiții ideale și identificarea din date afectate de zgomot. În cazul datelor curate, metoda bazată pe spațiul nul SVD a condus la reziduuri foarte mici și la soluții admisibile pentru toate configurațiile analizate, confirmând implementarea corectă a relației de identificare.

Pentru datele zgomotoase, aplicarea directă a metodei pe date perturbate nu a furnizat soluții acceptabile. Problemele au fost legate fie de nerespectarea condițiilor de normalizare, fie de lipsa unui spațiu nul numeric adecvat, ceea ce arată sensibilitatea formulării directe la zgomotul prezent în stări.

Varianta derivativă filtrată cu regularizare Tikhonov a îmbunătățit parțial rezultatele, însă nu a fost suficientă pentru toate cazurile analizate. Deși filtrarea reduce oscilațiile semnalelor măsurate, estimarea derivatelor rămâne sensibilă, iar unele soluții au fost respinse din cauza indicatorilor de admisibilitate sau a reziduurilor de validare ridicate.

Forma integrală cu regularizare Tikhonov a fost varianta care a îndeplinit simultan criteriile impuse în cazul datelor zgomotoase. Aceasta a condus la reziduuri de validare acceptabile, la transformări de coordonate admisibile și la termeni de decuplare utilizabili, reducând dependența de derivarea numerică punctuală.

Validarea în buclă închisă a confirmat că soluțiile selectate pot fi introduse efectiv în legea de control. Pentru datele curate, metoda bazată pe spațiul nul SVD rămâne varianta potrivită, iar pentru datele zgomotoase metoda integrală regularizată conduce la stabilizarea sistemelor analizate, cu semnale de comandă limitate.

În ansamblu, rezultatele testelor susțin folosirea formei integrale cu regularizare Tikhonov pentru cazul datelor zgomotoase. Aceasta reprezintă varianta finală păstrată în lucrare pentru identificarea funcțiilor necesare liniarizării prin reacție de la stare atunci când măsurătorile de stare sunt perturbate.

Capitolul 4

Concluzii

4.1 Sinteza lucrării

Această lucrare a analizat problema liniarizării prin reacție de la stare dintr-o perspectivă bazată pe date, cu accent pe situația în care informațiile disponibile despre sistem nu sunt ideale, ci sunt afectate de zgomot de măsurare. Tema se încadrează la intersecția dintre controlul neliniar clasic și metodele moderne data-driven, unde scopul nu este doar aplicarea unei teorii cunoscute, ci adaptarea acesteia la un context în care modelul complet al sistemului nu este folosit direct în etapa de identificare.

Parcursul lucrării a fost construit gradual. Mai întâi a fost prezentat cadrul clasic al liniarizării prin reacție de la stare, pentru a introduce noțiunile necesare și pentru a clarifica rolul transformării de coordonate, al termenului de decuplare și al legii de control, fiind baza teoretică necesară pentru înțelegerea abordării dezvoltate ulterior.

Pe acest fundament a fost analizată formularea data-driven, în care funcțiile necesare liniarizării nu mai sunt calculate direct din expresiile analitice ale sistemului, ci sunt identificate din date. Într-un prim pas a fost considerat cazul ideal, fără zgomot, pentru a verifica faptul că relația de identificare este construită corect. Ulterior, analiza a fost extinsă către cazul mai dificil al datelor zgomotoase, unde stările măsurate sunt perturbate, iar intrarea este considerată cunoscută și fără zgomot.

O parte importantă a lucrării a fost dedicată tratării efectului zgomotului. În acest context au fost analizate variante de filtrare, regularizare și formulări integrale, cu scopul de a obține soluții stabile numeric și utilizabile în legea de control. Astfel, accentul nu a fost pus doar pe obținerea unor coeficienți care satisfac o relație de identificare, ci pe verificarea faptului că soluțiile rezultate pot fi folosite efectiv pentru controlul sistemelor neliniare.

Implementarea a fost realizată în MATLAB, prin secvențe dedicate pentru generarea datelor, introducerea zgomotului, construcția matricelor de identificare, calculul coeficienților și validarea în buclă închisă și prin realizarea unei interfațe MATLAB pentru afișarea, organizarea rezultatelor și urmărirea mai clară a indicatorilor numerici, a comparației dintre metode și a graficelor obținute, oferind o formă mai accesibilă de analiză a rezultatelor.

4.2 Rezultate obținute și contribuții

Un prim rezultat al lucrării este clarificarea modului în care liniarizarea prin reacție de la stare este formulată în cazul clasic, atunci când modelul sistemului este cunoscut. Această etapă a fost necesară pentru a înțelege ce funcții trebuie determinate și ce condiții trebuie respectate pentru ca o lege de control să poată transforma dinamica neliniară într-o formă liniară echivalentă. De asemenea, această etapă a stabilit legătura directă dintre teoria clasică și formularea data-driven analizată ulterior.

Rezultatul central al lucrării constă în implementarea metodei data-driven pentru identificarea elementelor necesare liniarizării prin reacție de la stare. În cazul fără zgomot, metoda bazată pe spațiul nul și pe descompunerea în valori singulare a condus la rezultate foarte bune. Reziduurile au fost foarte mici, iar soluțiile obținute au respectat condițiile de admisibilitate, fapt ce confirmă că, atunci când datele sunt curate, informația necesară pentru reconstrucția funcțiilor de liniarizare poate fi extrasă corect din date.

Un rezultat important îl reprezintă analiza cazului cu date zgomotoase. Testele au arătat că zgomotul prezent în stări influențează puternic estimarea derivatelor și poate afecta stabilitatea numerică a soluțiilor. Aplicarea directă a metodei ideale pe date perturbate nu a fost suficientă. În mai multe cazuri, soluțiile obținute nu au respectat normalizările, condițiile de admisibilitate sau nu au putut fi utilizate în legea de control. Această observație evidențiază faptul că trecerea de la cazul ideal la cazul zgomotos nu este directă.

Pentru reducerea influenței zgomotului au fost comparate mai multe variante de identificare. Varianta directă aplicată pe date perturbate a avut rolul de a arăta sensibilitatea metodei de bază. Varianta cu derivate filtrate și regularizare Tikhonov a oferit unele îmbunătățiri, dar a rămas influențată de erorile introduse de derivarea numerică. Forma integrală cu regularizare Tikhonov a avut comportarea cea mai bună, deoarece reduce dependența de derivarea punctuală și conduce la soluții mai stabile numeric.

Pe baza rezultatelor obținute, forma integrală regularizată a fost păstrată ca metodă finală pentru cazul datelor zgomotoase, furnizând rezultate acceptabile pentru toate sistemele analizate, atât SISO, cât și MIMO. Soluțiile obținute au respectat criteriile de admisibilitate și au putut fi utilizate în simulările în buclă închisă. Din acest punct de vedere, metoda integrală a reprezentat elementul central al extinderii către date perturbate. Această alegere este importantă deoarece nu se bazează doar pe reducerea reziduuului numeric, ci și pe capacitatea soluției de a rămâne utilizabilă în legea de control. Astfel, metoda finală nu a fost selectată exclusiv pe baza identificării, ci și pe baza comportării în buclă închisă.

Un alt rezultat relevant este definirea unui proces de validare mai complet. Soluțiile nu au fost evaluate doar prin reziduuul de identificare, deoarece un reziduu mic nu garantează automat o transformare utilizabilă sau o lege de control stabilizatoare. Din acest motiv, au fost analizate și condițiile de admisibilitate ale transformării de coordonate și ale termenului de decuplare. Această etapă a permis eliminarea soluțiilor degenerate și păstrarea doar a soluțiilor care pot fi folosite în buclă închisă.

Validarea finală a fost realizată prin simulări în buclă închisă. Soluțiile acceptate au

fost introduse în legea de control, iar sistemele au fost simulate pentru a verifica stabilizarea în jurul punctului de echilibru. Rezultatele au arătat că metoda bazată pe SVD este potrivită pentru date ideale, iar forma integrală cu regularizare Tikhonov permite obținerea unui comportament stabil și în cazul datelor zgomotoase. De asemenea, semnalele de comandă au rămas în limite numerice rezonabile, fără creșteri excesive.

Din punct de vedere practic, implementarea MATLAB a avut un rol important în organizarea și verificarea rezultatelor. Scripturile dezvoltate permit reluarea etapelor de generare a datelor, identificare, comparație și validare, iar interfața MATLAB completează această implementare printr-o afișare mai clară a rezultatelor. Rolul acesteia este de a grupa informațiile importante și de a face mai ușoară interpretarea rezultatelor obținute.

Comparativ cu abordarea clasică, metoda data-driven reduce dependența de modelul matematic explicit. Rezultatele arată însă că această flexibilitate vine cu anumite condiții: datele trebuie să fie suficient de informative, dicționarele de funcții trebuie alese corespunzător, iar soluțiile trebuie validate atât numeric, cât și prin simulări în buclă închisă. În plus, cazul zgomotos este mai apropiat de situațiile practice, dar aduce dificultăți suplimentare prin sensibilitatea la erorile de măsurare.

Principalele contribuții personale ale lucrării sunt:

- implementarea metodei data-driven pentru identificarea funcțiilor $\hat{\tau}(x)$, $\hat{\delta}(x)$ și $\hat{\gamma}(x)$, necesare liniarizării prin reacție de la stare;
- verificarea metodei în cazul ideal, fără zgomot, folosind spațiul nul al matricei de identificare și descompunerea în valori singulare;
- extinderea analizei către cazul datelor zgomotoase, cu zgomot introdus pe stări și cu intrare considerată cunoscută și neperturbată;
- compararea mai multor variante de identificare pentru date perturbate: aplicarea directă pe date zgomotoase, forma derivativă filtrată și forma integrală regularizată;
- selectarea formei integrale cu regularizare Tikhonov ca variantă finală pentru cazul zgomotos, pe baza reziduurilor, a condițiilor de admisibilitate și a validării în buclă închisă;
- testarea metodei pe sisteme SISO și MIMO cu niveluri diferite de dificultate, de la cazuri simple până la sisteme cu decuplare dependentă de stare;
- stabilirea unui proces de validare bazat pe reziduuri, admisibilitatea transformării de coordonate, admisibilitatea termenului de decuplare și simularea în buclă închisă;
- dezvoltarea unei interfețe MATLAB pentru organizarea, compararea și afișarea rezultatelor obținute.

4.3 Direcții de dezvoltare

O primă direcție de dezvoltare este extinderea metodei către validarea pe sisteme reale sau pe platforme experimentale. În lucrarea de față, datele au fost generate prin simulare, ceea ce a permis controlul condițiilor inițiale, al nivelului de zgomot și al semnalelor de intrare utilizate pentru identificare. Acest cadru este potrivit pentru verificarea inițială a metodei, însă nu surprinde toate efectele care apar într-un proces fizic. Într-un sistem real pot apărea întârzieri de măsurare, saturații ale actuatorilor, zgomote dependente de senzor, erori de calibrare, perturbații externe sau diferențe între comanda calculată și comanda aplicată efectiv. Testarea pe o platformă reală ar permite evaluarea mai riguroasă a metodei în condiții practice.

O altă direcție importantă este tratarea cazului în care intrarea nu mai este considerată neafectată de zgomot. În implementarea realizată, zgomotul a fost introdus pe stările măsurate, iar intrarea a fost considerată cunoscută și neperturbată, deoarece reprezintă semnalul impus în simulare și salvat în setul de date. În aplicații reale, comanda efectivă poate fi influențată de dinamica actuatorilor, de saturații, de limitări hardware sau de erori de conversie. Așadar, o dezvoltare realistă ar fi formularea metodei pentru date în care atât stările, cât și intrările sunt afectate de incertitudini, iar metoda s-ar apropia de situațiile întâlnite în practică.

O direcție relevantă este îmbunătățirea modului de alegere a dicționarilor de funcții candidate și a parametrilor de regularizare. În lucrarea de față, dicționarele au fost alese manual, după structura sistemelor testate, iar parametrul de regularizare a fost stabilit astfel încât soluțiile să fie stabile numeric și potrivite pentru validarea în buclă închisă. Aceste alegeri influențează direct calitatea rezultatului, deoarece un dicționar prea simplu poate să nu surprindă dinamica sistemului, iar unul prea bogat poate conduce la probleme numerice și la soluții greu de interpretat. În mod asemănător, o regularizare prea mică poate păstra sensibilitatea la zgomot, în timp ce o regularizare prea mare poate produce o soluție prea netezită. În continuare, s-ar putea utiliza metode sparse, criterii de selecție automată a termenilor, proceduri de eliminare a funcțiilor nerelevante sau metode automate pentru alegerea parametrului de regularizare, precum validarea pe un set separat de date, curba L sau validarea încrucișată. Astfel, metoda ar deveni mai puțin dependentă de alegeri manuale și ar putea fi aplicată mai ușor pe sisteme mai complexe.

Pe lângă aspectele legate de date, dicționare și parametri numerici, metoda poate fi dezvoltată și din punct de vedere teoretic. O direcție importantă este introducerea unor garanții de stabilitate și robustețe. În această lucrare, stabilitatea a fost verificată numeric prin simulări în buclă închisă, iar soluțiile au fost acceptate pe baza reziduurilor, a condițiilor de admisibilitate și a comportării sistemului controlat, verificări necesare, dar care nu oferă întotdeauna o garanție teoretică pe o regiune mai largă a spațiului stărilor. Metoda ar putea fi completată cu instrumente bazate pe funcții Lyapunov, inegalități matriciale sau condiții de robustețe care să permită garantarea soluției identificate.

O altă dezvoltare posibilă este extinderea metodei către sisteme cu grad relativ incomplet. În lucrarea de față au fost analizate sisteme cu grad relativ complet, caz în

care transformarea de coordonate permite includerea întregii dinamici relevante în forma liniarizată. În practică pot apărea însă sisteme care au dinamici interne, zerouri dinamice sau structuri în care gradul relativ este mai mic decât ordinul sistemului. Pentru astfel de cazuri, nu este suficientă doar identificarea transformării de coordonate și a termenului de decuplare, ci trebuie analizată și dinamica internă rămasă. Tratarea acestui tip de sisteme ar reprezenta o extindere teoretică importantă și ar crește aplicabilitatea metodei.

O direcție practică și realistă este integrarea metodei cu strategii de control care țin cont de constrângeri. În implementarea curentă, regulatorul este proiectat pe forma liniarizată a sistemului, iar validarea urmărește stabilizarea și nivelul comenzii. În aplicații reale, însă, comanda poate fi limitată, stările pot avea domenii admisibile, iar depășirea acestor limite poate produce comportamente nedorite. În continuare, legea de control obținută prin liniarizare ar putea fi combinată cu metode de control predictiv, control robust sau mecanisme de saturare controlată. Această direcție ar permite folosirea metodei în situații în care stabilizarea nu este singurul criteriu, ci trebuie respectate și limite fizice ale sistemului.

O altă direcție utilă este analiza mai atentă a calității datelor folosite pentru identificare. Într-o abordare bazată pe date, rezultatul depinde de bogăția traiectoriilor, de alegerea condițiilor inițiale, de forma semnalelor de intrare și de perioada de eșantionare. Dacă datele nu explorează suficient regiunea de interes, soluția identificată poate avea reziduuri bune pe setul de identificare, dar poate conduce la performanțe slabe pe alte traiectorii. O dezvoltare viitoare ar putea include criterii pentru alegerea automată a semnalelor de intrare, verificarea informativității datelor și selectarea regiunii în care soluția este considerată validă.

O altă direcție de continuare este dezvoltarea unei variante adaptive sau online a metodei. În lucrarea de față, identificarea este realizată offline, pe baza unui set de date generat anterior. În unele aplicații, sistemul poate suferi modificări în timp, iar o soluție identificată inițial poate deveni mai puțin potrivită. O variantă online ar permite actualizarea coeficienților pe măsură ce apar date noi, cu condiția ca actualizarea să fie realizată controlat, fără a pierde stabilitatea sistemului în buclă închisă. Această direcție ar necesita mecanisme de detecție a schimbărilor, criterii de acceptare a noilor soluții și metode de actualizare care să nu producă variații bruște ale legii de control.

În final, o direcție de dezvoltare cu aplicabilitate practică este construirea unui flux mai automatizat pentru liniarizarea prin reacție de la stare din date. Acesta ar putea porni de la datele măsurate ale sistemului, ar evalua calitatea acestora, ar selecta dicționarul de funcții, metoda de identificare și parametrul de regularizare, iar apoi ar verifica automat soluția prin criterii de admisibilitate și simulări în buclă închisă. Interfața MATLAB realizată în lucrare poate reprezenta un punct de plecare pentru această dezvoltare, prin extinderea ei cu opțiuni de încărcare a datelor externe, salvare automată a rezultatelor, generare de rapoarte și afișare a unor avertizări atunci când soluția nu respectă pragurile impuse. O astfel de abordare ar apropia formularea teoretică de utilizarea practică a metodei și ar putea constitui baza unui studiu mai amplu privind metodele data-driven robuste pentru controlul sistemelor neliniare.

Bibliografie

- [1] A. Isidori, *Nonlinear Control Systems*, 3rd ed. Springer, 1995.
- [2] H. Nijmeijer and A. Van der Schaft, *Nonlinear dynamical control systems*. Springer, 1990, vol. 175.
- [3] M. Boufadene, *Nonlinear control systems using MATLAB®*. CRC Press, 2018.
- [4] C. De Persis, D. Gadginmath, F. Pasqualetti, and P. Tesi, “Feedback linearization through the lens of data,” *IEEE Transactions on Automatic Control*, 2025.
- [5] C. I. Byrnes and A. Isidori, “Nonlinear control systems,” Tech. Rep., 2001.
- [6] R. W. Brockett, “Feedback invariants for nonlinear systems,” *IFAC Proceedings Volumes*, vol. 11, no. 1, pp. 1115–1120, 1978.
- [7] B. Jaw Jakubczyk and W. Respondek, “On linearization of control systems,” *Bull. Acad. Polon. Sci. Ser. Sci. Math.*, vol. 28, no. 9-10, pp. 517–522, 1980.
- [8] V. Mihaly, M. Șuşcă, and P. Dobra, “Fixed-structure robust feedback linearization for full relative degree nonlinear systems,” *IEEE/CAA Journal of Automatica Sinica*, vol. 12, no. 10, pp. 2026–2039, 2025.
- [9] F. A. Pellegrino, F. Blanchini, G. Fenu, and E. Salvato, “Closed-loop control from data-driven open-loop optimal control trajectories,” in *2022 European Control Conference (ECC)*. IEEE, 2022, pp. 1379–1384.
- [10] F. Dörfler, J. Coulson, and I. Markovsky, “Bridging direct and indirect data-driven control formulations via regularizations and relaxations,” *IEEE Transactions on Automatic Control*, vol. 68, no. 2, pp. 883–897, 2022.
- [11] C. De Persis and P. Tesi, “Designing experiments for data-driven control of nonlinear systems,” *IFAC-PapersOnLine*, vol. 54, no. 9, pp. 285–290, 2021.
- [12] S. L. Brunton, J. L. Proctor, and J. N. Kutz, “Discovering governing equations from data by sparse identification of nonlinear dynamical systems,” *Proceedings of the national academy of sciences*, vol. 113, no. 15, pp. 3932–3937, 2016.

- [13] T. Dai and M. Sznaier, “A semi-algebraic optimization approach to data-driven control of continuous-time nonlinear systems,” *IEEE Control Systems Letters*, vol. 5, no. 2, pp. 487–492, 2020.
- [14] M. Guo, C. De Persis, and P. Tesi, “Data-driven stabilizer design and closed-loop analysis of general nonlinear systems via taylor expansion,” *arXiv preprint arXiv:2209.01071*, 2022.
- [15] M. Alsalti, V. G. Lopez, J. Berberich, F. Allgöwer, and M. A. Müller, “Data-based control of feedback linearizable systems,” *IEEE Transactions on Automatic Control*, vol. 68, no. 11, pp. 7014–7021, 2023.
- [16] J. Umlauf and S. Hirche, “Feedback linearization based on gaussian processes with event-triggered online learning,” *IEEE Transactions on Automatic Control*, vol. 65, no. 10, pp. 4154–4169, 2019.
- [17] T. Westenbroek, D. Fridovich-Keil, E. Mazumdar, S. Arora, V. Prabhu, S. S. Sastry, and C. J. Tomlin, “Feedback linearization for uncertain systems via reinforcement learning,” in *2020 IEEE international conference on robotics and automation (ICRA)*. IEEE, 2020, pp. 1364–1371.
- [18] L. Fraile, M. Marchi, and P. Tabuada, “Data-driven stabilization of siso feedback linearizable systems,” *arXiv preprint arXiv:2003.14240*, 2020.
- [19] C.-Y. Chang and A. Bernstein, “Robust data-driven control for systems with noisy data,” *arXiv preprint arXiv:2207.09587*, 2022.
- [20] A. Luppi, C. De Persis, and P. Tesi, “On data-driven stabilization of systems with nonlinearities satisfying quadratic constraints,” *Systems & Control Letters*, vol. 163, p. 105206, 2022.
- [21] T. Dai and M. Sznaier, “Nonlinear data-driven control via state-dependent representations,” in *2021 60th IEEE Conference on Decision and Control (CDC)*. IEEE, 2021, pp. 5765–5770.
- [22] R. W. Schafer, “What is a savitzky-golay filter?[lecture notes],” *IEEE Signal processing magazine*, vol. 28, no. 4, pp. 111–117, 2011.
- [23] A. Savitzky and M. J. Golay, “Smoothing and differentiation of data by simplified least squares procedures,” *Analytical chemistry*, vol. 36, no. 8, pp. 1627–1639, 1964.
- [24] A. N. Tikhonov and V. Y. Arsenin, “Solutions of Ill-Posed Problems,” 1977.
- [25] G. H. Golub and C. F. Van Loan, *Matrix computations*. JHU press, 2013.